Clasificación bayesiana de poblaciones estelares: Identificación de miembros en el cúmulo M41.

Daniel Fajardo Poveda[1]

Universidad de los Andes, Bogotá, Colombia

March 2, 2026

Este trabajo presenta un análisis de membresía estelar para el cúmulo abierto mediante la aplicación de un marco de inferencia bayesiana basado en datos astrométricos. Se seleccionó una muestra de estrellas localizadas a una distancia nominal de 625 pc, cubriendo un radio de búsqueda de 30 pc para asegurar la inclusión de componentes periféricos del sistema. La metodología empleada consistió en el cálculo de probabilidades de pertenencia a partir de los movimientos propios en ascensión recta y declinación. Para el modelado estocástico, se asumió una distribución normal bivariada circular para representar la dinámica del cúmulo, contrastándola con una distribución bivariada elíptica para las estrellas de campo.

Al establecer un umbral de clasificación de $P > 0.5$, se identificaron 85 elementos como miembros probables del cúmulo. La validación fotométrica de estos candidatos mediante el Diagrama Color-Magnitud muestra una distribución coherente con estrellas de edad joven-intermedia situadas en la secuencia principal, corroborando la eficacia del método estadístico para la segregación de poblaciones estelares en este sistema.

Palabras clave: Astrometría; M41; Inferencia Bayesiana; Distribución Bivariada; Secuencia Principal; Diagrama Color-Magnitud.

Objetivos

- Determinar el conjunto de los nueve parámetros fundamentales del modelo (μ_{xc}, μ_{yc}, σ_c, μ_{xf}, μ_{yf}, σ_{xf}, σ_{yf}, ρ, n_f) que maximizan la función de verosimilitud, permitiendo una descripción estadística precisa tanto del cúmulo como de las estrellas de campo.

[1]Contacto: d.fajardo@uniandes.edu.co

- Calcular las probabilidades de pertenencia individuales para cada estrella en la muestra y clasificar como miembros del cúmulo a aquellos objetos que presenten una probabilidad $P > 0.5$.

- Construir y analizar el Diagrama Color-Magnitud (DCM) de la población identificada para verificar su coherencia física con la secuencia principal y las propiedades evolutivas de M41.

I. Introducción

Los cúmulos abiertos, ubicados predominantemente en el disco de la Vía Láctea, son agrupaciones de estrellas que nacieron a partir de la misma nube molecular gigante. Por lo tanto, sus miembros comparten la misma edad, distancia y composición química inicial (metalicidad). Al graficar estas estrellas en un Diagrama Color-Magnitud (DCM), la gran mayoría se alinea en una franja diagonal conocida como la secuencia principal, compuesta principalmente por estrellas jóvenes, calientes y azules que se encuentran fusionando hidrógeno en su núcleo. A medida que el cúmulo envejece, las estrellas más masivas agotan su combustible y abandonan la secuencia principal, desplazándose hacia la derecha y arriba en el diagrama para formar la rama de las gigantes rojas, una región habitada por estrellas evolucionadas, más frías en su superficie pero extremadamente luminosas (Karttunen et al. 2007).

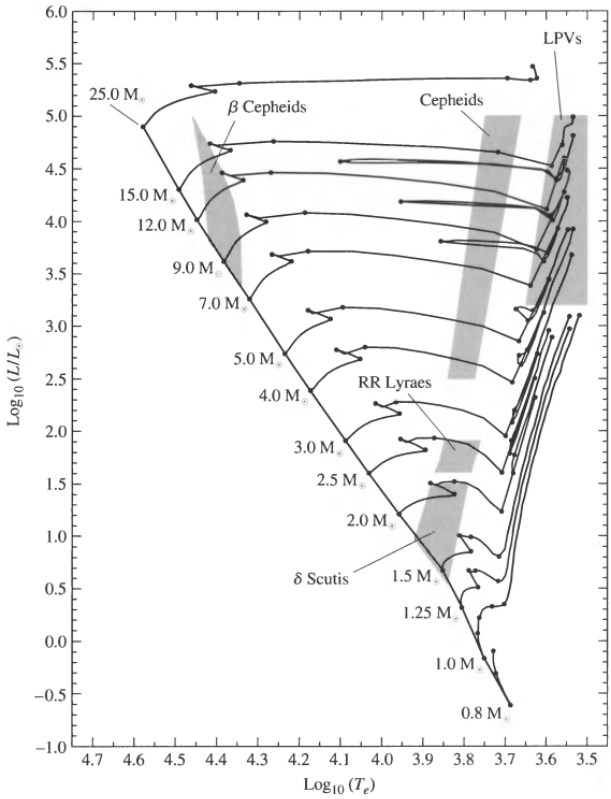

Figure 1: Diagrama de Hertzprung-Russell esquemático ilustrando la secuencia principal de estrellas jóvenes y azules, y la desviación hacia la rama de las gigantes rojas para las estrellas más evolucionadas. Tomado de Ostlie & Carroll (1996).

El objeto central de este estudio, Messier 41 (M41 o NGC 2287), es un cúmulo abierto situado en la constelación de Canis Major. Constituye un laboratorio astrofísico ideal para validar técnicas fotométricas debido a su proximidad y baja extinción interestelar. En la literatura reciente, gracias a los datos astrométricos de la misión *Gaia*, se ha determinado con gran precisión que M41 se encuentra a una distancia aproximada de 725 parsecs, con una edad estimada en torno a los 200 millones de años Harris et al. (1993). Históricamente, las observaciones terrestres lograban identificar unos pocos cientos de miembros debido a las limitaciones de magnitud del cielo nocturno local y la contaminación visual; sin embargo, los algoritmos modernos de pertenencia basados en los movimientos propios de *Gaia DR3* han revelado que el cúmulo alberga más de mil estrellas ligadas gravitacionalmente.

Figure 2: Imagen del cúmulo abierto M41 (NGC 2287). Extraido de NOIRLab/NSF/AURA (2020).

Históricamente, la identificación de miembros de un cúmulo se basaba en la inspección visual de placas fotográficas y mediciones manuales de movimientos propios, un proceso limitado por grandes errores sistemáticos y una baja resolución angular. No fue sino hasta misiones como *Hipparcos* y, más recientemente, la misión Gaia de la Agencia Espacial Europea (ESA), que la astrometría alcanzó una precisión de microsegundos de arco (μas). Gaia utiliza un sistema de escaneo continuo mediante dos telescopios que proyectan sus campos de visión sobre un plano focal común de mil millones de píxeles, permitiendo derivar movimientos propios con una fidelidad sin precedentes al medir el cambio de posición de las estrellas sobre múltiples épocas de observación.

Desde el punto de vista dinámico, un cúmulo abierto como M41 se origina a partir del colapso de una única nube molecular gigante. Debido a este origen común, las estrellas resultantes comparten un vector de velocidad espacial casi idéntico. Al encontrarse a una distancia similar de la Tierra ($d \approx 625$ pc), el efecto de perspectiva hace que su movimiento aparente en la esfera celeste, traducido como movimientos propios en ascensión recta ($\mu_{\alpha*}$) y declinación (μ_δ), sea prácticamente uniforme.

En este trabajo, se asume que la dispersión y el centro de la distribución de movimientos propios del cúmulo son idénticos para ambas coordenadas ($\sigma_\alpha = \sigma_\delta$). Físicamente, este supuesto de isotropía tiene sentido en cúmulos jóvenes y relajados, donde no existen direcciones preferenciales de movimiento tras el proceso de formación. Al estar gravitacionalmente ligados, los componentes del cúmulo se desplazan como un bloque coherente a través del campo estelar de fondo, lo que permite modelar su distribución como una función bivariada circular, facilitando la discriminación estadística frente a las estrellas de campo, cuya cinemática es mucho más dispersa y elíptica.

Modelo de Membresía y Formalismo Bayesiano

Para discriminar los miembros del cúmulo de las estrellas de campo, se emplea un modelo de mezcla estadística basado en los trabajos fundamentales de (Vasilevskis 1958) y (Slovak 1977). El problema se plantea mediante una función de densidad de probabilidad total $\Phi(\mu_{\alpha*}, \mu_\delta)$, que combina la contribución del cúmulo (c) y del campo (f):

$$\Phi(\mu_{\alpha*}, \mu_\delta) = (1 - n_f) \cdot \Psi_c(\mu_{\alpha*}, \mu_\delta) + n_f \cdot \Psi_f(\mu_{\alpha*}, \mu_\delta) \tag{1}$$

Donde n_f representa la fracción de estrellas de campo en la muestra. La distribución del cúmulo se asume como una función normal bivariada isotrópica (circular):

$$\Psi_c = \frac{1}{2\pi\sigma_c^2} \exp\left[-\frac{1}{2}\left(\frac{(\mu_{\alpha*} - \mu_{xc})^2 + (\mu_\delta - \mu_{yc})^2}{\sigma_c^2}\right)\right] \tag{2}$$

Por otro lado, la distribución del campo se modela como una normal bivariada elíptica para capturar la anisotropía de la rotación galáctica:

$$\Psi_f = \frac{1}{2\pi\sigma_{xf}\sigma_{yf}\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{\Delta\mu_x^2}{\sigma_{xf}^2} - \frac{2\rho\Delta\mu_x\Delta\mu_y}{\sigma_{xf}\sigma_{yf}} + \frac{\Delta\mu_y^2}{\sigma_{yf}^2}\right)\right] \tag{3}$$

donde $\Delta\mu_x = (\mu_{\alpha*} - \mu_{xf})$ y $\Delta\mu_y = (\mu_\delta - \mu_{yf})$. En total, el modelo depende de un vector de 9 parámetros: $\theta = (\mu_{xc}, \mu_{yc}, \sigma_c, \mu_{xf}, \mu_{yf}, \sigma_{xf}, \sigma_{yf}, \rho, n_f)$.

Para hallar los valores óptimos de estos parámetros, maximizamos la función de log-verosimilitud ($\ln \mathcal{L}$):

$$\ln \mathcal{L}(\theta) = \sum_{i=1}^{N} \ln \left[\Phi(\mu_{\alpha*,i}, \mu_{\delta,i}|\theta)\right] \tag{4}$$

Este proceso de optimización numérica se llevó a cabo utilizando la librería *scipy.optimize.minimize* de Python, seleccionando específicamente el algoritmo *L-BFGS-B* (Limited-memory Broyden-Fletcher-Goldfarb-Shanno Bound). Este método es un optimizador cuasi-Newton eficiente para problemas con un gran número de variables que permite establecer límites (*bounds*) para los parámetros (como asegurar que las dispersiones σ sean siempre positivas y que n_f se encuentre en el intervalo $[0, 1]$).

Una vez obtenidos los parámetros óptimos $\hat{\theta}$, la probabilidad de que una estrella i pertenezca al cúmulo se calcula mediante el teorema de Bayes como:

$$P_{c,i} = \frac{(1 - n_f)\Psi_c(\mu_{\alpha*,i}, \mu_{\delta,i})}{\Phi(\mu_{\alpha*,i}, \mu_{\delta,i})} \tag{5}$$

II. Metodología y Resultados

Diagrama PVD y supuestos estadísticos

Los datos extraídos del *Gaia Archive* comprendían un total de 1468 estrellas dentro de la región de interés. A partir de estos datos construimos el Diagrama de Vector Puntual (PVD) utilizando los movimientos propios en ascensión recta ($\mu_{\alpha*}$) y declinación (μ_δ).

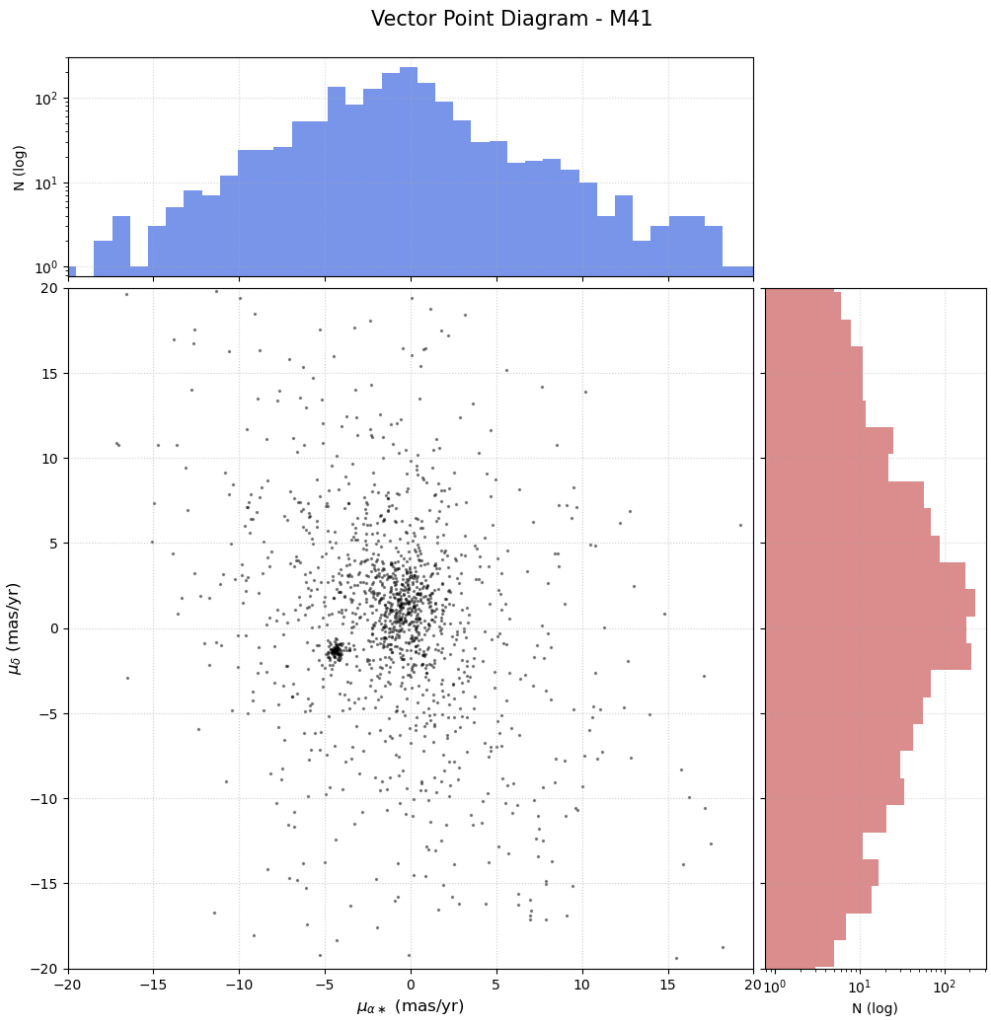

Figure 3: Diagrama de Vector Puntual (PVD) de las 1468 estrellas seleccionadas.

En el PVD es posible distinguir visualmente dos distribuciones principales: una correspondiente a las estrellas de campo y otra asociada a las estrellas pertenecientes al cúmulo. La concentración más compacta representa el cúmulo, mientras que la distribución más extendida corresponde al campo estelar.

Con el objetivo de estimar los centros y las dispersiones de ambas poblaciones, se intentó inicialmente ajustar un modelo de mezclas gaussianas, asumiendo que la distribución gaussiana del cúmulo era isotrópica y, por tanto, tenía la misma dispersión en ascensión recta y declinación. Sin embargo, los valores obtenidos para los centros y desviaciones estándar de

las distribuciones de campo y cúmulo no permitieron que el modelo bayesiano convergiera de manera satisfactoria en la separación probabilística de ambas poblaciones.Por lo que la estimacion final se de estos centros y desviaciones se realizó de manera visual, utilizando el PVD como referencia para identificar las regiones de mayor concentración de estrellas que correspondían al cúmulo y al campo.

Para la correlación entre los movimientos propios de ambos grupos se asumió inicialmente una correlación nula. Esta hipótesis se fundamenta en que la distribución de movimientos propios del cúmulo es estadísticamente independiente de la del campo estelar.

En términos geométricos, esto implica que las elipses de dispersión no presentan una orientación preferencial común y que el ángulo entre los ejes principales de las varianzas no es significativamente pequeño; es decir, no existe una alineación fuerte que sugiera correlación lineal dominante entre ambas componentes en el cúmulo.

El número de elementos de campo fue estimado mediante *TopCat*, donde es posible aislar visualmente un subconjunto aproximado que contiene el cúmulo. A partir de esta selección preliminar se determinó que aproximadamente el 90% de la muestra corresponde a estrellas de campo, mientras que el 10% restante pertenece al cúmulo. Esto establece una fracción inicial $n_f \approx 0.9$ para el campo.

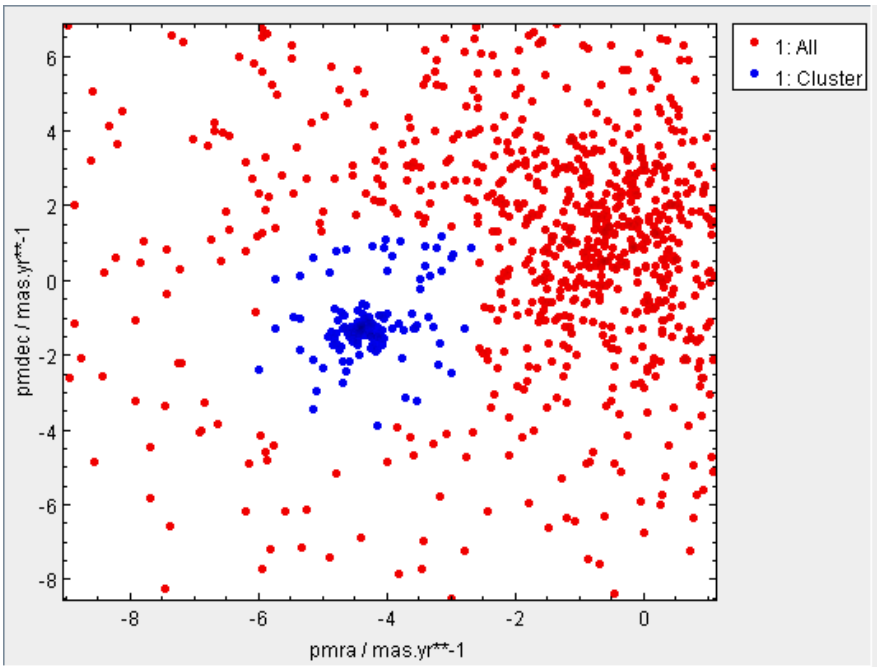

Figure 4: Selección preliminar en TopCat para estimar las fracciones relativas de estrellas de campo y del cúmulo.

Maximización de la verosimilitud

Una vez establecidos estos valores iniciales (*initial guesses*), se procedió a maximizar la función de verosimilitud mediante el algoritmo L-BFGS-B, el cual permite optimización con restricciones en los parámetros.

El vector de parámetros $\boldsymbol{\theta}$ contiene nueve parámetros. Los valores obtenidos tras la optimización fueron los siguientes:

Parámetro	**Valor**
μ_{x_c} (Cluster RA)	-4.3668
μ_{y_c} (Cluster Dec)	-1.3399
σ_c (Cluster Dispersion)	0.2634
μ_{x_f} (Field RA)	-0.7413
μ_{y_f} (Field Dec)	0.6276
σ_{x_f} (Field RA Dispersion)	5.1545
σ_{y_f} (Field Dec Dispersion)	7.3152
ρ (Correlation)	-0.2816
n_f (Field Fraction)	0.9455

Table 1: Parámetros obtenidos mediante la maximización de la verosimilitud con L-BFGS-B.

Clasificación probabilística de miembros

Una vez estimada, mediante inferencia bayesiana, la probabilidad de pertenencia al cúmulo para cada estrella de la muestra, se procedió a establecer un criterio de clasificación basado en un umbral probabilístico.

Se adoptó un valor de corte de $P = 0.5$, de manera que todas las estrellas con probabilidad de pertenencia mayor a este umbral fueron clasificadas como miembros del cúmulo, mientras que aquellas con probabilidades menores fueron consideradas estrellas de campo.

El histograma de probabilidades obtenidas muestra una clara separación entre la población dominante de campo (con probabilidades cercanas a cero) y el subconjunto asociado al cúmulo (con probabilidades más altas).

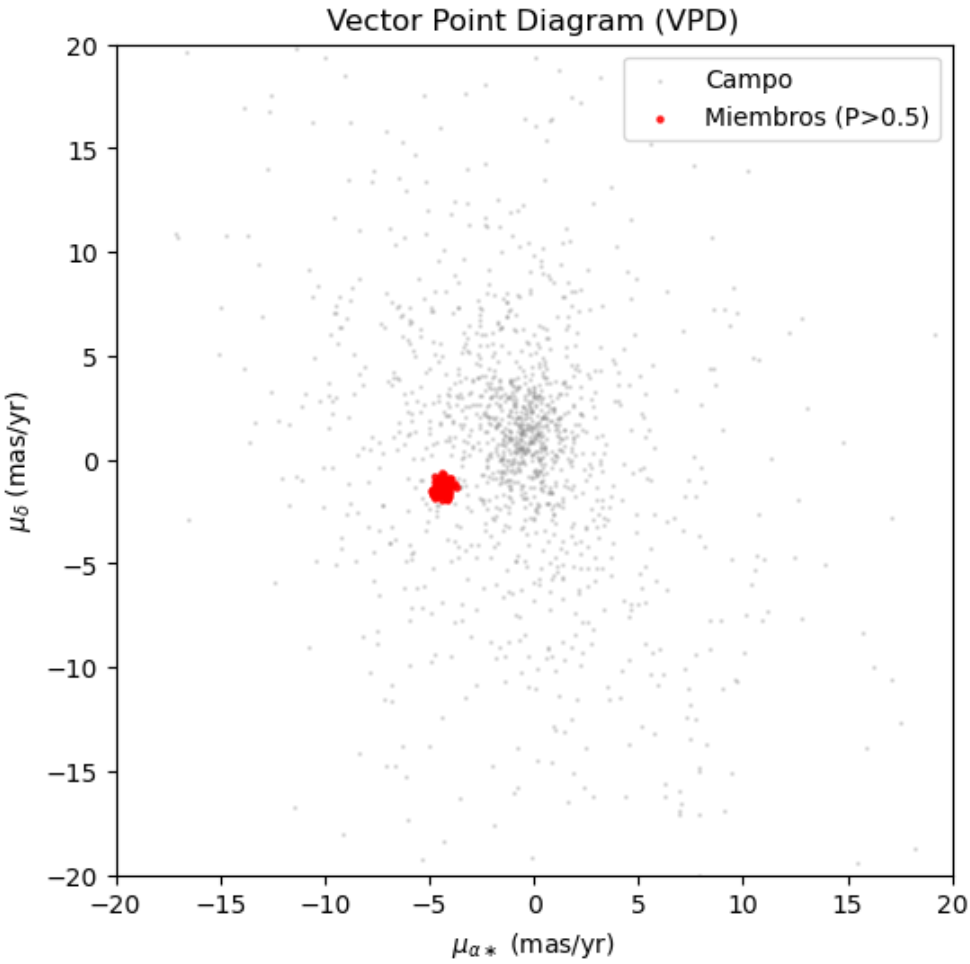

Figure 5: Histograma de las probabilidades de pertenencia al cúmulo. La línea vertical indica el umbral de selección $P = 0.5$. Las estrellas con $P > 0.5$ fueron clasificadas como miembros del cúmulo, mientras que aquellas con $P < 0.5$ fueron consideradas estrellas de campo.

Como resultado de este procedimiento de selección, se identificaron 85 estrellas como miembros probables del sistema.

Diagrama Color–Magnitud

Finalmente, se construyó el diagrama color–magnitud (CMD) utilizando las estrellas clasificadas como miembros probables del cúmulo. En este diagrama es posible observar que los elementos identificados como pertenecientes al cúmulo se distribuyen a lo largo de la secuencia principal.

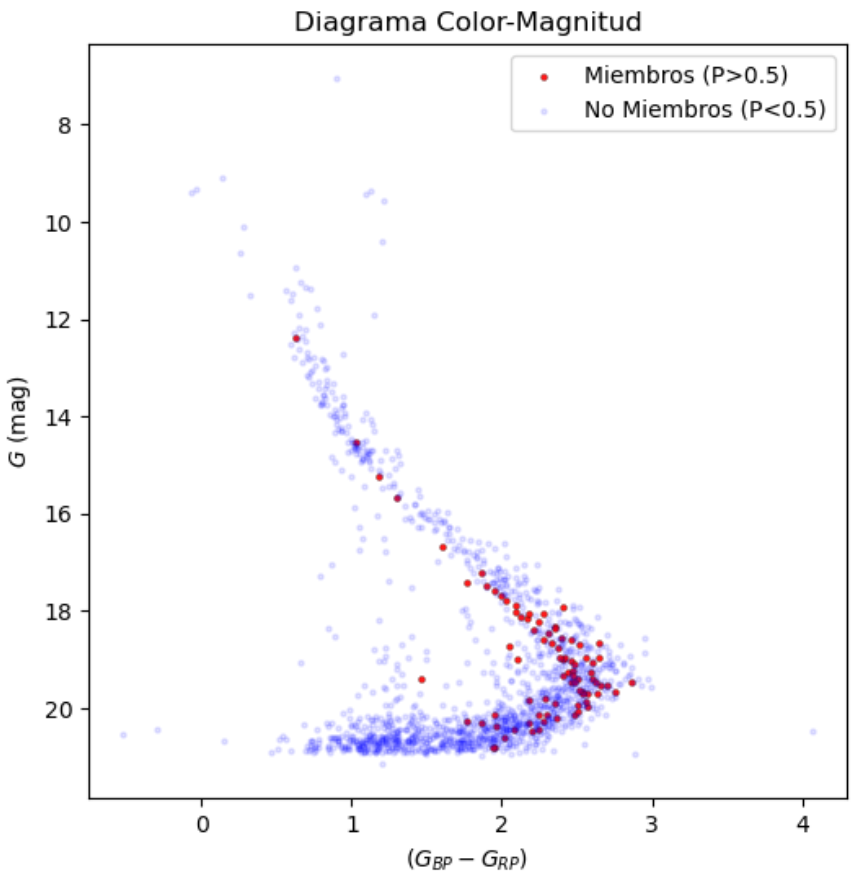

Figure 6: Diagrama color–magnitud del campo analizado. Las estrellas clasificadas como miembros del cúmulo se concentran a lo largo de la secuencia principal.

La concentración de las estrellas del cúmulo dentro de la secuencia principal indica que la población estelar de M41 corresponde a un sistema de edad joven–intermedia, en concordancia con lo esperado para este objeto. Además, se observa que las magnitudes y colores (indicadores de temperatura efectiva) de las estrellas miembros presentan una coherencia notable entre sí, lo que refuerza la consistencia de la selección basada en probabilidades de pertenencia.

Por otra parte, se evidencia una ausencia de estrellas del cúmulo en el régimen de magnitudes muy brillantes. En esta región del diagrama únicamente se observan estrellas de campo brillantes que no pertenecen al sistema, lo cual es consistente con la masa y el estado evolutivo esperado para el cúmulo.

III. Conclusiones

En este trabajo se realizó un análisis cinemático y fotométrico del cúmulo abierto M41 a partir de 1468 estrellas extraídas del *Gaia Archive*. El estudio se centró en la separación estadística entre estrellas de campo y miembros del cúmulo mediante el uso de movimientos propios y un enfoque de inferencia bayesiana.

El Diagrama de Vector Puntual (PVD) permitió identificar visualmente dos poblaciones diferenciadas: una concentración compacta asociada al cúmulo y una distribución más dispersa correspondiente al campo estelar. Aunque inicialmente se intentó ajustar un modelo de mezclas gaussianas bajo la hipótesis de isotropía para el cúmulo, los parámetros obtenidos no permitieron una convergencia adecuada en el modelo bayesiano. Posteriormente, mediante la maximización de la función de verosimilitud con el algoritmo L-BFGS-B, se estimaron de manera consistente los nueve parámetros del modelo, incluyendo centros, dispersiones, correlación y fracción de campo.

El valor optimizado de la fracción de campo ($n_f = 0.9455$) resultó coherente con la estimación preliminar obtenida en TopCat, confirmando que la muestra está dominada por estrellas de campo. A partir de las probabilidades de pertenencia calculadas para cada estrella, se adoptó un umbral de decisión de $P > 0.5$, lo que permitió identificar 85 miembros probables del cúmulo.

El diagrama color–magnitud construido con estos miembros seleccionados mostró una clara concentración a lo largo de la secuencia principal. Esta distribución confirma que la población estelar de M41 corresponde a un cúmulo de edad joven–intermedia, tal como se espera para este tipo de sistemas abiertos. Asimismo, la coherencia en magnitudes y colores entre las estrellas seleccionadas respalda la validez del método estadístico empleado. La ausencia de miembros en el régimen de magnitudes más brillantes, donde predominan estrellas de campo, es consistente con las características evolutivas esperadas para el cúmulo.

En conjunto, los resultados obtenidos demuestran que la combinación de análisis cinemático en el espacio de movimientos propios con clasificación bayesiana constituye una herramienta

robusta para la determinación de membresía en cúmulos abiertos, permitiendo una separación estadísticamente fundamentada entre poblaciones superpuestas en el campo galáctico.

IV. Repositorio de Código

Para acceder al repositorio del proyecto, visite: https://github.com/DanielFajardo1/Astronomia-con-Machine-Learning.git

Bibliography

Harris, G. L. H., Fitzgerald, M. P., & Reed, B. C. 1993, Astronomical Journal, 106, 1533

Karttunen, H. et al. 2007, Fundamental Astronomy, Springer

NOIRLab/NSF/AURA. 2020, M41, NGC 2287, https://noirlab.edu/public/images/noao-m41/, imagen astronómica del cúmulo abierto M41 en Canis Major (libre con atribución)

Ostlie, A. & Carroll, W. 1996, Modern Stellar Astrophysics, Addison-Wesley Publishing Company

Slovak, M. H. 1977, Astronomical Journal, 82, 818

Vasilevskis, S., K. A. . P. G. 1958, Astronomical Journal, 63, 387