Pertenencia Estelar en Cúmulos Abiertos: Un Enfoque Bayesiano y de Clustering

Daniel Fajardo Poveda[1]

Universidad de los Andes, Bogotá, Colombia

March 7, 2026

En este trabajo se realiza un estudio de pertenencia estelar en los cúmulos abiertos M41 (NGC 2248) y Coma Berenices utilizando dos enfoques metodológicos diferentes. En primer lugar, se aplica el método de inferencia bayesiana para estimar la probabilidad de pertenencia de las estrellas a cada cúmulo a partir de sus movimientos propios en ascensión recta y declinación, utilizando los datos astrométricos proporcionados por la misión Gaia. Este procedimiento se implementa siguiendo la metodología desarrollada en el laboratorio 2.

Adicionalmente, se aborda el mismo problema mediante el algoritmo de aprendizaje no supervisado HDBSCAN, considerando un espacio tridimensional definido por los movimientos propios en ascensión recta y declinación, junto con la paralaje. Este enfoque permite identificar agrupamientos estelares basados en la densidad en el espacio de parámetros astrométricos.

La comparación entre ambos métodos evidencia que HDBSCAN es capaz de identificar miembros de los cúmulos que fueron descartados por el modelo bayesiano. Asimismo, al incorporar la información de la paralaje, el método de clustering permite excluir estrellas que, considerando únicamente los movimientos propios, parecían pertenecer al cúmulo pero que en realidad forman parte del campo estelar.

Palabras clave: Cúmulos abiertos, pertenencia estelar, inferencia bayesiana, HDBSCAN, Gaia DR3, movimientos propios, paralaje.

Objetivos

[1]Contacto: d.fajardo@uniandes.edu.co

- Implementar la metodología desarrollada en el Laboratorio 2, basada en un modelo de inferencia bayesiana aplicado a los movimientos propios en ascensión recta y declinación, con el fin de estimar las estrellas miembro de los cúmulos abiertos M41 y Coma Berenices, utilizando como criterio de pertenencia una probabilidad $P > 0.5$.

- Implementar el algoritmo de aprendizaje no supervisado HDBSCAN para estimar las estrellas miembro de los cúmulos M41 y Coma Berenices, considerando un espacio tridimensional definido por los movimientos propios en ascensión recta, declinación y la paralaje.

- Comparar los resultados obtenidos mediante ambos métodos con el propósito de analizar las diferencias en la identificación de miembros estelares dentro de los cúmulos estudiados.

I. Introducción

Los cúmulos abiertos, ubicados predominantemente en el disco de la Vía Láctea, son agrupaciones de estrellas que nacieron a partir de la misma nube molecular gigante. Por lo tanto, sus miembros comparten la misma edad, distancia y composición química inicial (metalicidad). Al graficar estas estrellas en un Diagrama Color-Magnitud (DCM), la gran mayoría se alinea en una franja diagonal conocida como la secuencia principal, compuesta principalmente por estrellas jóvenes, calientes y azules que se encuentran fusionando hidrógeno en su núcleo. A medida que el cúmulo envejece, las estrellas más masivas agotan su combustible y abandonan la secuencia principal, desplazándose hacia la derecha y arriba en el diagrama para formar la rama de las gigantes rojas, una región habitada por estrellas evolucionadas, más frías en su superficie pero extremadamente luminosas (Karttunen et al. 2007).

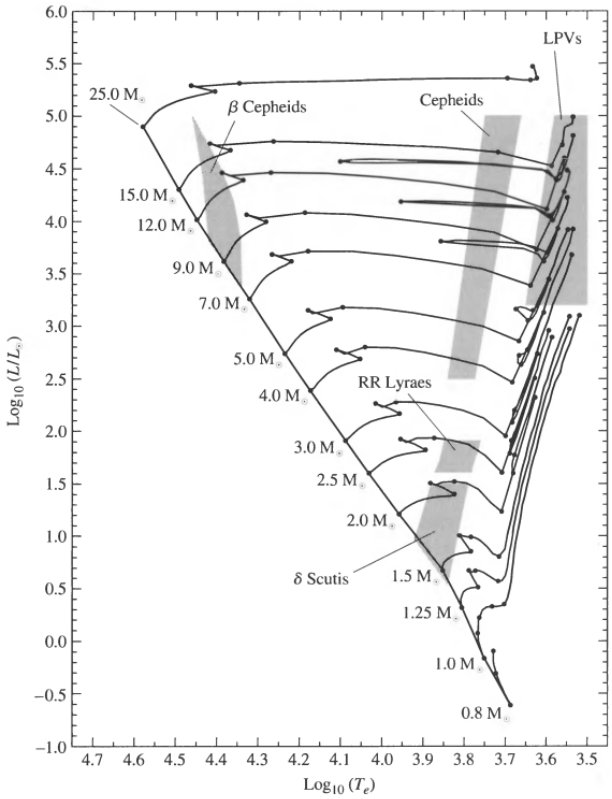

Figure 1: Diagrama de Hertzprung-Russell esquemático ilustrando la secuencia principal de estrellas jóvenes y azules, y la desviación hacia la rama de las gigantes rojas para las estrellas más evolucionadas. Tomado de Ostlie & Carroll (1996).

Uno de los objetos centrales de este estudio, Messier 41 (M41 o NGC 2287), es un cúmulo abierto situado en la constelación de Canis Major. Constituye un laboratorio astrofísico ideal para validar técnicas fotométricas debido a su proximidad y baja extinción interestelar. En la literatura reciente, gracias a los datos astrométricos de la misión *Gaia*, se ha determinado con gran precisión que M41 se encuentra a una distancia aproximada de 725 parsecs, con una edad estimada en torno a los 200 millones de años Harris et al. (1993). Históricamente, las observaciones terrestres lograban identificar unos pocos cientos de miembros debido a las limitaciones de magnitud del cielo nocturno local y la contaminación visual; sin embargo, los algoritmos modernos de pertenencia basados en los movimientos propios de *Gaia DR3* han revelado que el cúmulo alberga más de mil estrellas ligadas gravitacionalmente.

Figure 2: Imagen del cúmulo abierto M41 (NGC 2287). Extraido de NOIRLab/NSF/AURA (2020).

Este trabajo también considera el cúmulo abierto Coma Berenices (Melotte 111), localizado en la constelación de Coma Berenices. Este cúmulo es uno de los sistemas abiertos más cercanos al Sistema Solar y se caracteriza por su gran extensión angular en el cielo, lo cual ha dificultado históricamente la identificación completa de sus miembros. Estudios recientes basados en datos astrométricos de la misión *Gaia* han permitido determinar con mayor precisión sus propiedades fundamentales, estimando una distancia media de aproximadamente 85 parsecs y una edad cercana a los 700 millones de años. En cuanto a su población estelar, los análisis modernos de pertenencia indican que el cúmulo está compuesto por varios cientos de estrellas miembros, con estimaciones que oscilan entre ~ 200 y ~ 400 estrellas dependiendo de los criterios de selección y de los parámetros astrométricos considerados (**?**).

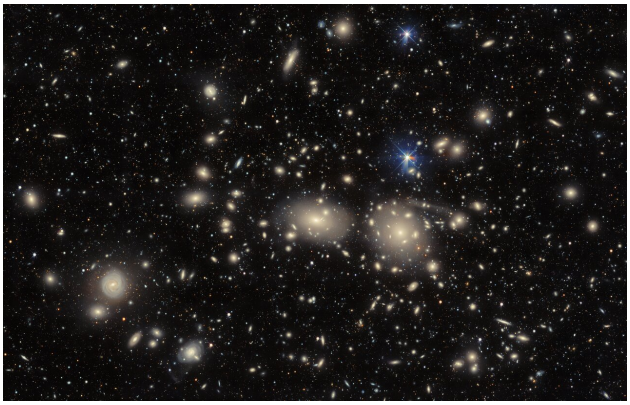

Figure 3: Imagen del cúmulo abierto Coma Berenices. Extraido de NOIRLab/NSF/AURA (2020).

Históricamente, la identificación de miembros de un cúmulo se basaba en la inspección visual de placas fotográficas y mediciones manuales de movimientos propios, un proceso limitado por grandes errores sistemáticos y una baja resolución angular. No fue sino hasta misiones como *Hipparcos* y, más recientemente, la misión Gaia de la Agencia Espacial Europea (ESA), que la astrometría alcanzó una precisión de microsegundos de arco (μas). Gaia utiliza un sistema de escaneo continuo mediante dos telescopios que proyectan sus campos de visión sobre un plano focal común de mil millones de píxeles, permitiendo derivar movimientos propios con una fidelidad sin precedentes al medir el cambio de posición de las estrellas sobre múltiples épocas de observación.

Desde el punto de vista dinámico, un cúmulo abierto como M41 se origina a partir del colapso de una única nube molecular gigante. Debido a este origen común, las estrellas resultantes comparten un vector de velocidad espacial casi idéntico. Al encontrarse a una distancia similar de la Tierra, el efecto de perspectiva hace que su movimiento aparente en la esfera celeste, traducido como movimientos propios en ascensión recta ($\mu_{\alpha*}$) y declinación (μ_δ), sea prácticamente uniforme.

En este trabajo, se asume que la dispersión y el centro de la distribución de movimientos propios del cúmulo son idénticos para ambas coordenadas ($\sigma_\alpha = \sigma_\delta$). Físicamente, este supuesto de isotropía tiene sentido en cúmulos jóvenes y relajados, donde no existen direcciones

preferenciales de movimiento tras el proceso de formación. Al estar gravitacionalmente ligados, los componentes del cúmulo se desplazan como un bloque coherente a través del campo estelar de fondo, lo que permite modelar su distribución como una función bivariada circular, facilitando la discriminación estadística frente a las estrellas de campo, cuya cinemática es mucho más dispersa y elíptica.

Modelo de Membresía y Formalismo Bayesiano

Para discriminar los miembros del cúmulo de las estrellas de campo, se emplea un modelo de mezcla estadística basado en los trabajos fundamentales de (Vasilevskis 1958) y (Slovak 1977). El problema se plantea mediante una función de densidad de probabilidad total $\Phi(\mu_{\alpha*}, \mu_\delta)$, que combina la contribución del cúmulo (c) y del campo (f):

$$\Phi(\mu_{\alpha*}, \mu_\delta) = (1 - n_f) \cdot \Psi_c(\mu_{\alpha*}, \mu_\delta) + n_f \cdot \Psi_f(\mu_{\alpha*}, \mu_\delta) \tag{1}$$

Donde n_f representa la fracción de estrellas de campo en la muestra. La distribución del cúmulo se asume como una función normal bivariada isotrópica (circular):

$$\Psi_c = \frac{1}{2\pi\sigma_c^2} \exp\left[-\frac{1}{2}\left(\frac{(\mu_{\alpha*} - \mu_{xc})^2 + (\mu_\delta - \mu_{yc})^2}{\sigma_c^2}\right)\right] \tag{2}$$

Por otro lado, la distribución del campo se modela como una normal bivariada elíptica para capturar la anisotropía de la rotación galáctica:

$$\Psi_f = \frac{1}{2\pi\sigma_{xf}\sigma_{yf}\sqrt{1-\rho^2}} \exp\left[-\frac{1}{2(1-\rho^2)}\left(\frac{\Delta\mu_x^2}{\sigma_{xf}^2} - \frac{2\rho\Delta\mu_x\Delta\mu_y}{\sigma_{xf}\sigma_{yf}} + \frac{\Delta\mu_y^2}{\sigma_{yf}^2}\right)\right] \tag{3}$$

donde $\Delta\mu_x = (\mu_{\alpha*} - \mu_{xf})$ y $\Delta\mu_y = (\mu_\delta - \mu_{yf})$. En total, el modelo depende de un vector de 9 parámetros: $\theta = (\mu_{xc}, \mu_{yc}, \sigma_c, \mu_{xf}, \mu_{yf}, \sigma_{xf}, \sigma_{yf}, \rho, n_f)$.

Para hallar los valores óptimos de estos parámetros, maximizamos la función de log-verosimilitud ($\ln \mathcal{L}$):

$$\ln \mathcal{L}(\theta) = \sum_{i=1}^{N} \ln \left[\Phi(\mu_{\alpha*,i}, \mu_{\delta,i}|\theta)\right] \tag{4}$$

Este proceso de optimización numérica se llevó a cabo utilizando la librería *scipy.optimize.minimize* de Python, seleccionando específicamente el algoritmo *L-BFGS-B* (Limited-memory Broyden-Fletcher-Goldfarb-Shanno Bound). Este método es un optimizador cuasi-Newton eficiente para problemas con un gran número de variables que permite establecer límites (*bounds*) para los parámetros (como asegurar que las dispersiones σ sean siempre positivas y que n_f se encuentre en el intervalo $[0, 1]$).

Una vez obtenidos los parámetros óptimos $\hat{\theta}$, la probabilidad de que una estrella i pertenezca al cúmulo se calcula mediante el teorema de Bayes como:

$$P_{c,i} = \frac{(1 - n_f)\Psi_c(\mu_{\alpha*,i}, \mu_{\delta,i})}{\Phi(\mu_{\alpha*,i}, \mu_{\delta,i})} \tag{5}$$

Modelo no supervisado: HDBSCAN

Para complementar el análisis de pertenencia estelar se empleó el algoritmo de aprendizaje no supervisado *HDBSCAN* (Hierarchical Density-Based Spatial Clustering of Applications with Noise). Este método pertenece a la familia de algoritmos de *clustering* basados en densidad, los cuales identifican agrupamientos de datos como regiones del espacio de parámetros donde la densidad de puntos es significativamente mayor que en su entorno.

La idea fundamental detrás de los métodos basados en densidad es que un cúmulo puede interpretarse como una región del espacio de características en la que los objetos se encuentran más próximos entre sí que al resto de los datos. En este contexto, las estrellas miembro de un cúmulo abierto tienden a agruparse en regiones compactas del espacio astrométrico (por ejemplo, movimientos propios y paralaje), mientras que las estrellas de campo se distribuyen de forma más dispersa. A diferencia de otros métodos de clustering, HDBSCAN permite identificar automáticamente regiones de distinta densidad y, además, clasifica de forma explícita los puntos que no pertenecen a ningún cúmulo como ruido.

El algoritmo construye inicialmente una representación jerárquica de las agrupaciones posibles a partir de estimaciones de densidad local. Posteriormente, esta jerarquía es condensada para seleccionar los clústeres más estables en función de la persistencia de las regiones densas a diferentes escalas. Este procedimiento permite detectar estructuras en los datos sin necesidad de especificar previamente el número de clústeres presentes en el conjunto de datos.

El comportamiento del algoritmo está controlado por varios hiperparámetros. En este trabajo se consideran principalmente dos de ellos:

- **min_cluster_size**: define el número mínimo de puntos necesario para que un grupo de datos sea considerado un clúster. Este parámetro controla la escala mínima de las estructuras que el algoritmo puede identificar y permite evitar la detección de agrupaciones espurias formadas por un número muy pequeño de objetos.

- **min_samples**: determina el número mínimo de vecinos requeridos para estimar la densidad local alrededor de cada punto. Valores mayores de este parámetro hacen que el algoritmo sea más conservador, aumentando la cantidad de puntos clasificados como ruido y reduciendo la probabilidad de identificar clústeres poco densos.

En el contexto de este trabajo, HDBSCAN se aplica en un espacio tridimensional definido por los movimientos propios en ascensión recta (μ_α), declinación (μ_δ) y la paralaje (ϖ), con el objetivo de identificar agrupaciones estelares correspondientes a los cúmulos abiertos estudiados y distinguirlas del campo estelar circundante.

II. Metodología y Resultados

II.A Modelo Bayesiano

Los datos extraídos del *Gaia Archive* comprenden un total de 2000 estrellas dentro de la región de interés para el cúmulo M41 y 5010 estrellas para el cúmulo Coma Berenices. A partir

de este conjunto de datos se construyó el Diagrama de Vector Puntual (PVD) utilizando los movimientos propios en ascensión recta ($\mu_{\alpha*}$) y declinación (μ_δ).

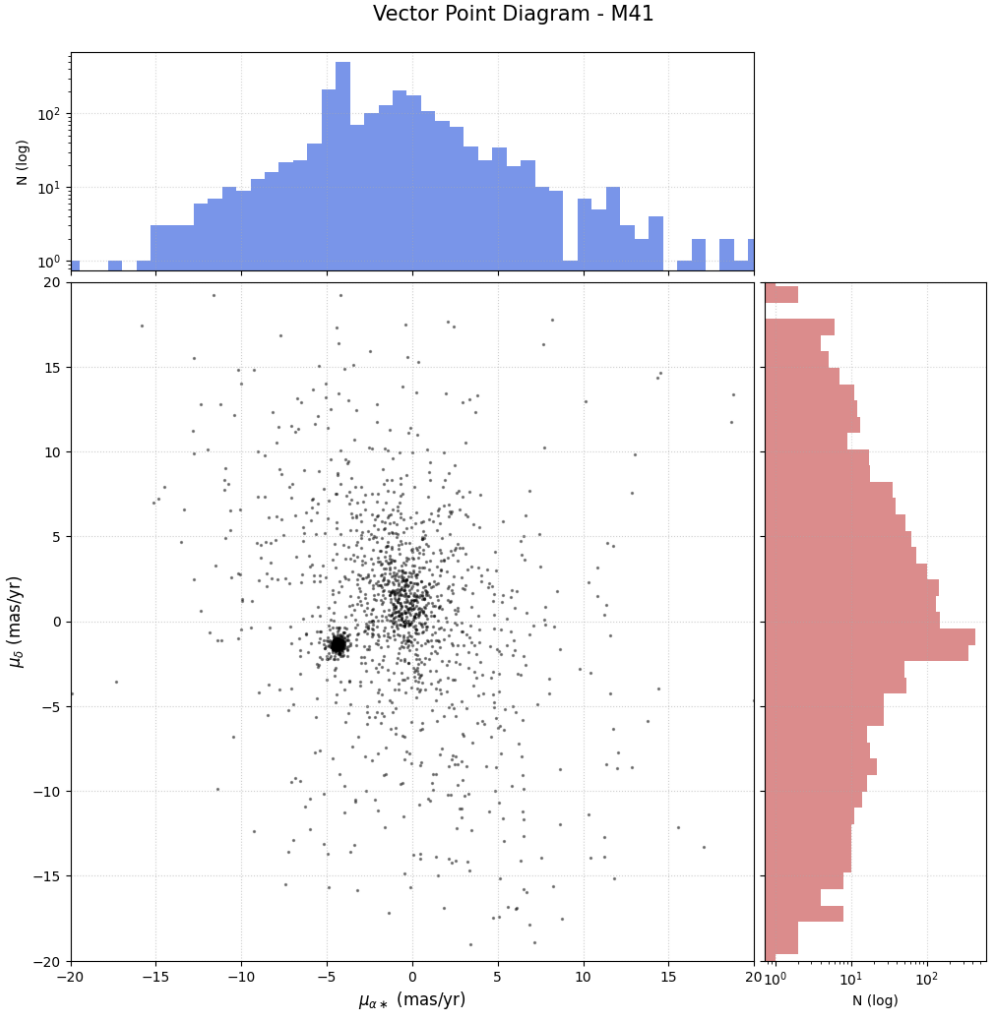

Figure 4: Diagrama de Vector Puntual (PVD) de las 2000 estrellas seleccionadas en la región del cúmulo M41.

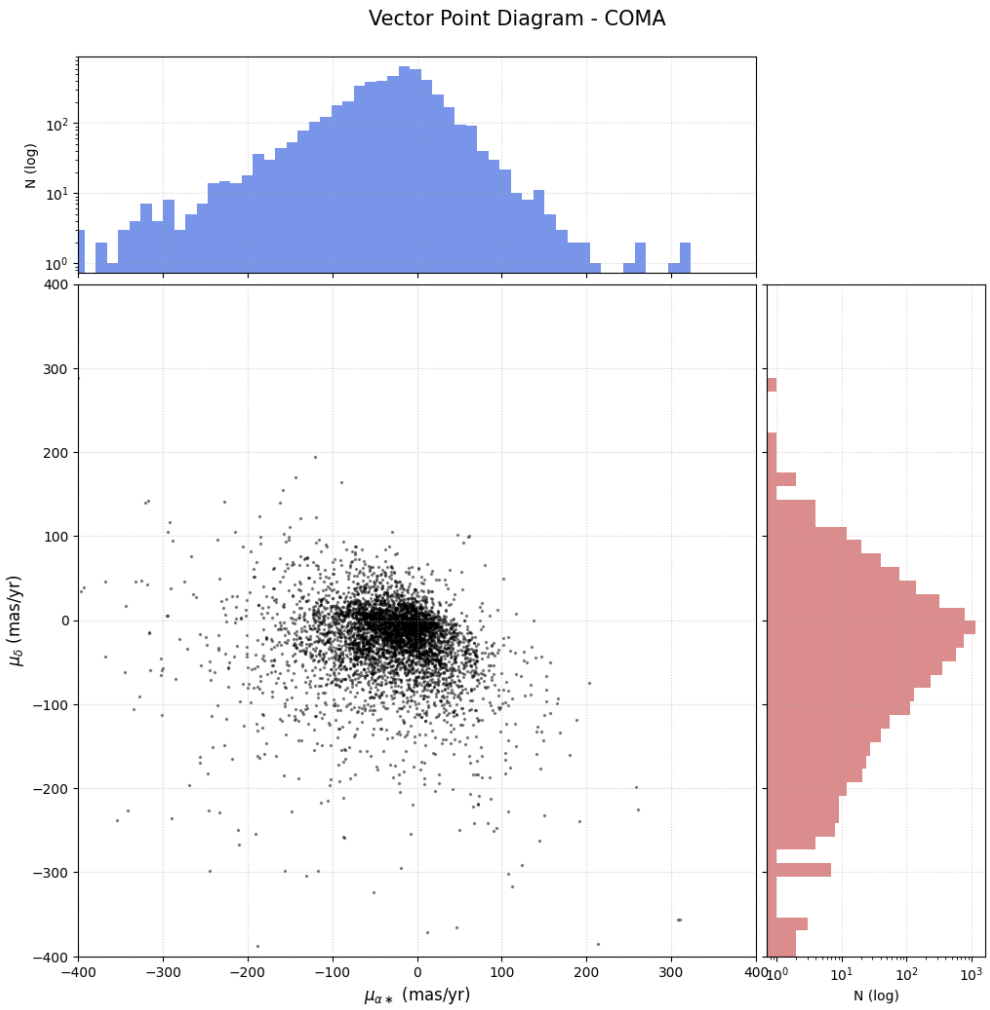

Figure 5: Diagrama de Vector Puntual (PVD) de las 5010 estrellas seleccionadas en la región del cúmulo Coma Berenices.

En el PVD correspondiente al cúmulo M41 es posible distinguir visualmente dos distribuciones principales: una asociada a las estrellas de campo y otra correspondiente a las estrellas pertenecientes al cúmulo. La concentración más compacta de puntos representa el grupo de estrellas que comparten movimientos propios similares, característicos de un sistema gravitacionalmente ligado, mientras que la distribución más extendida corresponde al campo estelar circundante.

Por otro lado, el PVD del cúmulo Coma Berenices presenta una distribución más dispersa en el espacio de movimientos propios. Esto sugiere una mayor contaminación por estrellas de campo y una menor concentración aparente de miembros del cúmulo en comparación con

M41, lo cual es consistente con la naturaleza más extendida y menos densa de este sistema estelar.

La maximización de la función de verosimilitud, la estimación de los parámetros iniciales y el cálculo de las probabilidades de pertenencia se realizaron siguiendo exactamente el procedimiento descrito en el Laboratorio 2, utilizando el formalismo de inferencia bayesiana previamente establecido.

Las distribuciones de probabilidad obtenidas presentan el comportamiento esperado. En particular, se observa un pico pronunciado en probabilidades cercanas a cero, asociado a las estrellas de campo, y un segundo pico en probabilidades cercanas a uno, correspondiente a las estrellas con alta probabilidad de pertenecer al cúmulo. Este patrón refleja la capacidad del modelo para distinguir entre ambas poblaciones en el espacio de movimientos propios.

No obstante, el modelo bayesiano presenta mayores dificultades al momento de identificar los miembros del cúmulo Coma Berenices. Esto se evidencia en la presencia de un número significativo de estrellas con probabilidades intermedias (entre 0.5 y 0.8), lo que indica una incertidumbre considerable en la clasificación de estos objetos como miembros del cúmulo o como parte del campo estelar.

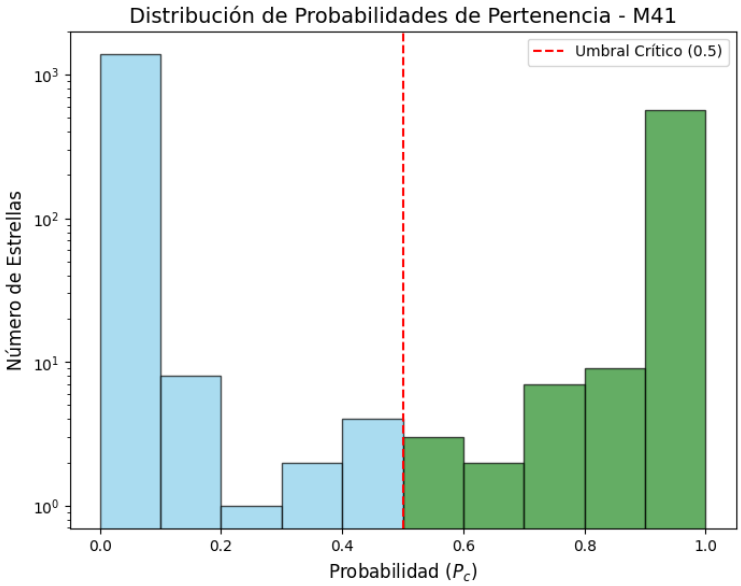

Figure 6: Distribución de probabilidades de pertenencia para el cúmulo M41.

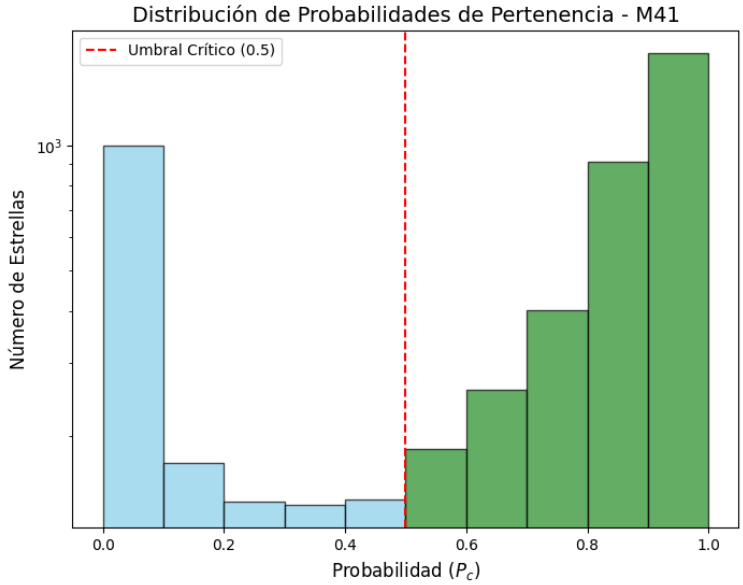

Figure 7: Distribución de probabilidades de pertenencia para el cúmulo Coma Berenices.

Adoptando un umbral de pertenencia de $P > 0.5$, se identificaron 590 estrellas miembro para el cúmulo M41 y 3425 estrellas para el cúmulo Coma Berenices. Considerando el número esperado de miembros reportado en la literatura para estos cúmulos, el resultado obtenido para M41 puede considerarse razonable. Sin embargo, el número de miembros estimado para Coma Berenices resulta significativamente mayor que el esperado.

Este resultado sugiere la presencia de una alta tasa de falsos positivos en la clasificación de miembros del cúmulo. Una posible explicación es la superposición cinemática entre las estrellas del cúmulo y el campo estelar circundante cuando se consideran únicamente los movimientos propios, lo que puede llevar al modelo a asignar probabilidades elevadas de pertenencia a estrellas que en realidad no forman parte del sistema.

Los valores obtenidos tras la optimización de los nueve parámetros del modelo, mediante la maximización de la función de verosimilitud utilizando el algoritmo L-BFGS-B, se presentan en las Tablas 1 y 2. Estos parámetros describen las propiedades cinemáticas de las dos poblaciones consideradas en el modelo: el cúmulo estelar y el campo estelar circundante.

Parámetro	**Valor**
μ_{x_c} (Cluster RA)	-4.3668
μ_{y_c} (Cluster Dec)	-1.3399
σ_c (Cluster Dispersion)	0.2634
μ_{x_f} (Field RA)	-0.7413
μ_{y_f} (Field Dec)	0.6276
σ_{x_f} (Field RA Dispersion)	5.1545
σ_{y_f} (Field Dec Dispersion)	7.3152
ρ (Correlation)	-0.2816
n_f (Field Fraction)	0.9455

Table 1: Parámetros obtenidos mediante la maximización de la verosimilitud con el algoritmo L-BFGS-B para el cúmulo M41.

Parámetro	**Valor**
μ_{x_c} (Cluster RA)	-20.2613
μ_{y_c} (Cluster Dec)	-12.8585
σ_c (Cluster Dispersion)	28.3730
μ_{x_f} (Field RA)	-54.8193
μ_{y_f} (Field Dec)	-42.3916
σ_{x_f} (Field RA Dispersion)	92.1156
σ_{y_f} (Field Dec Dispersion)	65.5906
ρ (Correlation)	-0.2877
n_f (Field Fraction)	0.3793

Table 2: Parámetros obtenidos mediante la maximización de la verosimilitud con el algoritmo L-BFGS-B para el cúmulo Coma Berenices.

Visualización de Miembros y Campo

Una vez identificados los miembros del cúmulo y las estrellas de campo, se procedió a visualizar la distribución de ambos grupos en el espacio de movimientos propios. En el caso de M41, los miembros del cúmulo se concentran claramente en una región compacta del PVD, mientras que las estrellas de campo se distribuyen de manera más dispersa. Para Coma Berenices, aunque se observa una concentración de miembros, la superposición con el campo es más significativa, lo que refleja la dificultad para discriminar entre ambas poblaciones utilizando únicamente los movimientos propios.

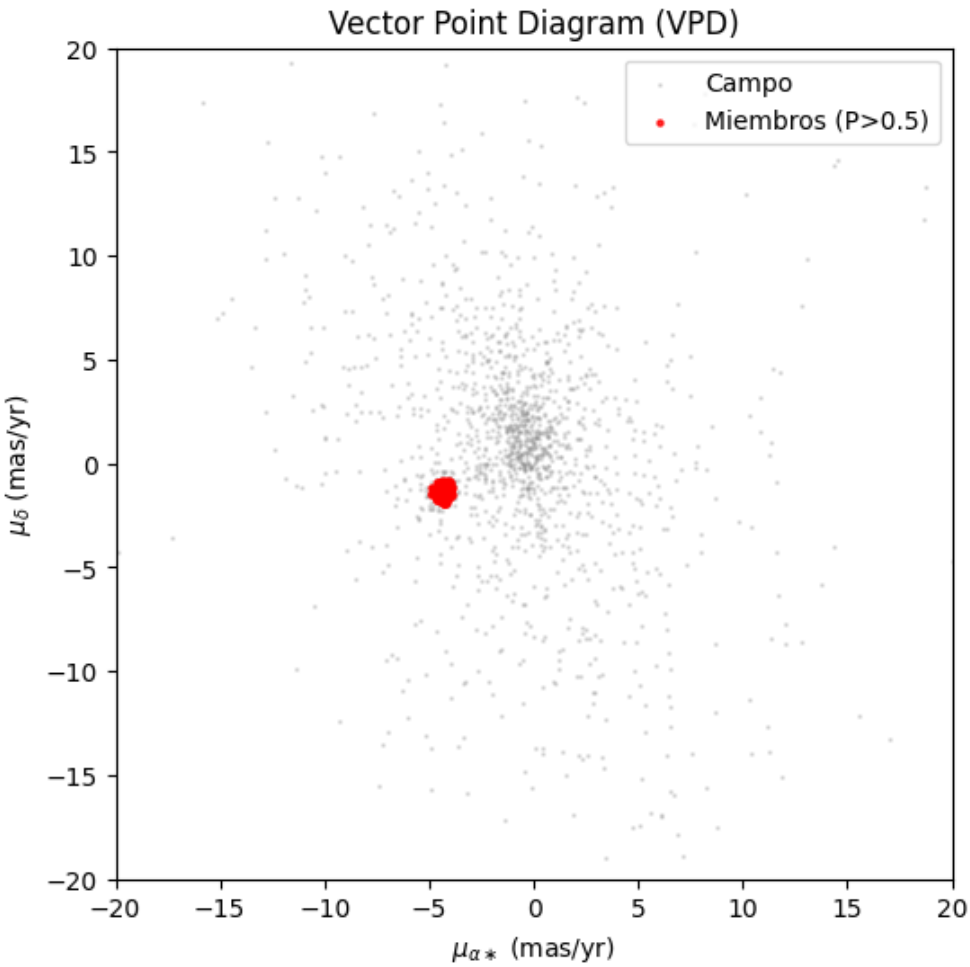

Figure 8: PVD del cúmulo M41 con los miembros del cúmulo destacados en rojo y las estrellas de campo en gris.

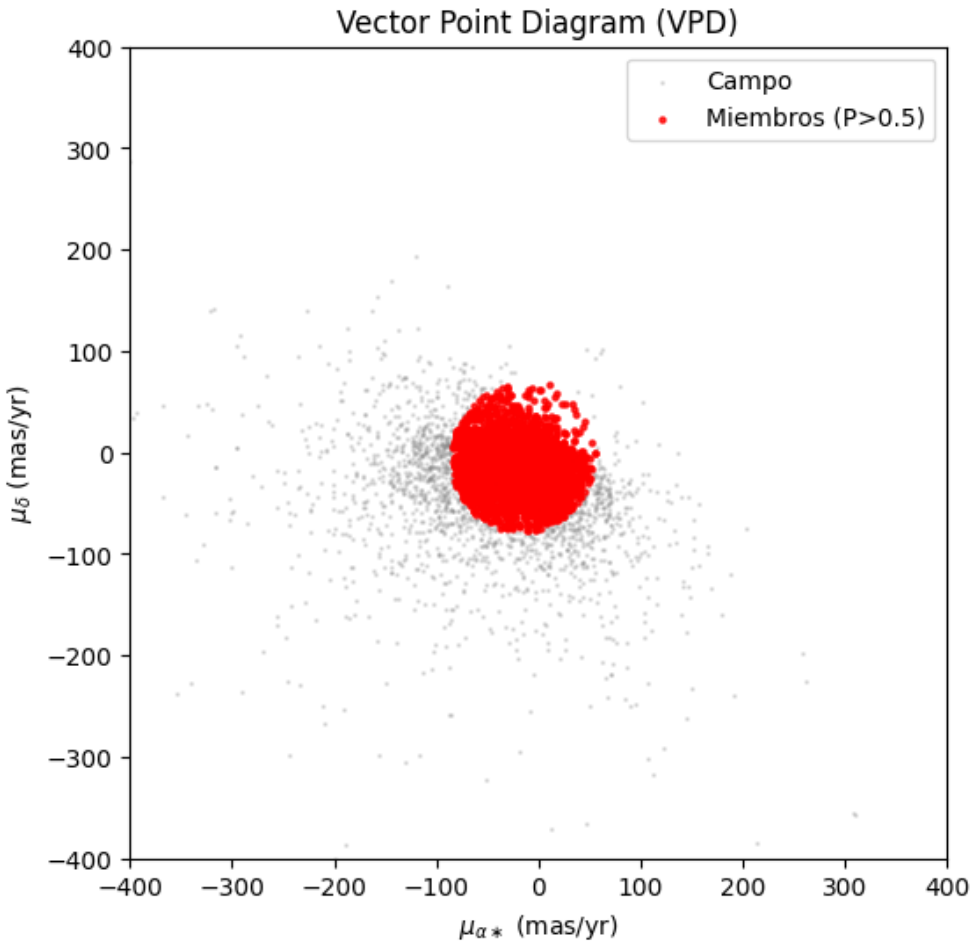

Figure 9: PVD del cúmulo Coma Berenices con los miembros del cúmulo destacados en rojo y las estrellas de campo en gris.

Finalmente, se construyeron los diagramaa color–magnitud (CMD) utilizando las estrellas clasificadas como miembros probables de los cúmulos. En estos diagramas es posible observar que los elementos identificados como pertenecientes a los cúmulos se distribuyen a lo largo de la secuencia principal.

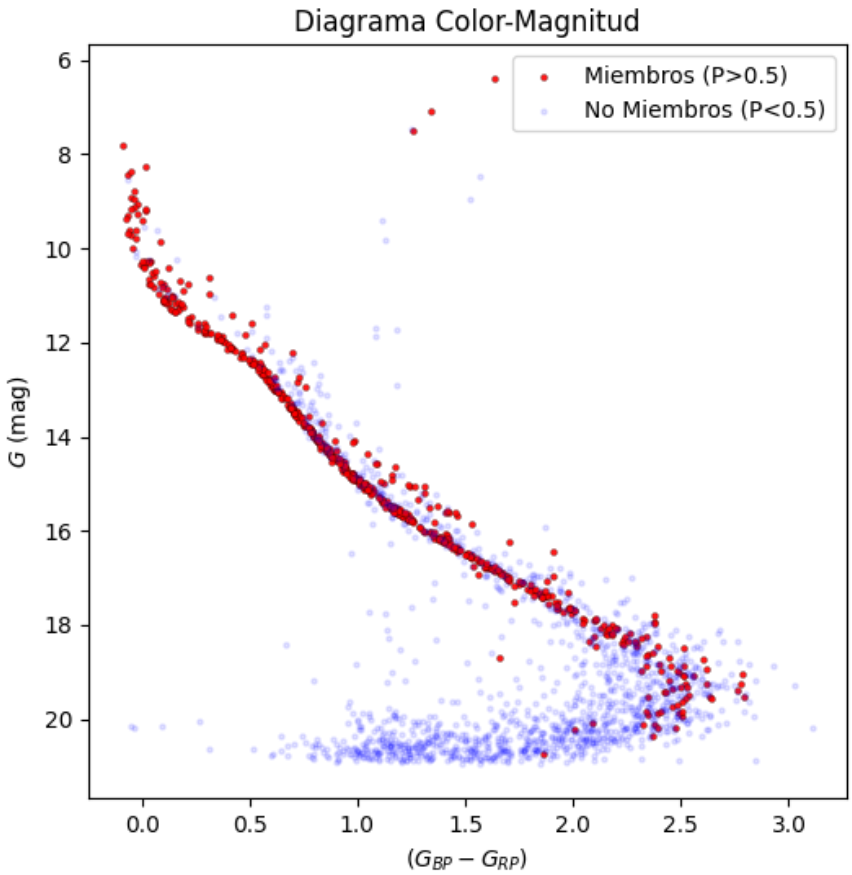

Figure 10: Diagrama color–magnitud del cúmulo M41. Las estrellas clasificadas como miembros del cúmulo se concentran a lo largo de la secuencia principal.

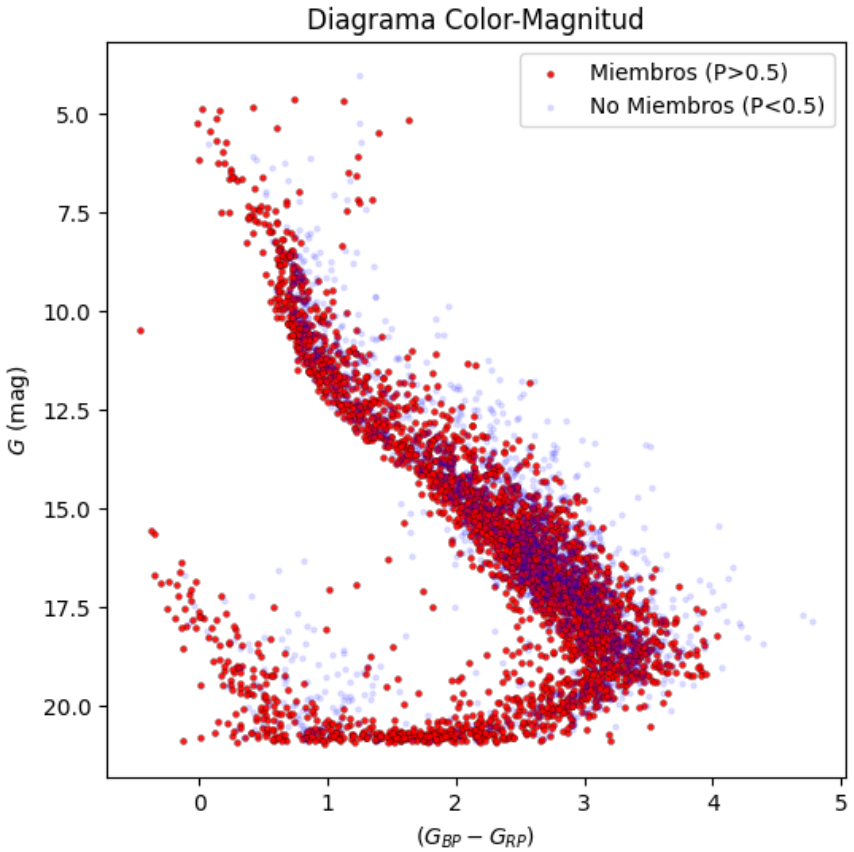

Figure 11: Diagrama color–magnitud del cúmulo Coma Berenices. Las estrellas clasificadas como miembros del cúmulo se concentran a lo largo de la secuencia principal y rama de enanas blancas.

La concentración de las estrellas del cúmulo dentro de la secuencia principal indica que la población estelar de M41 corresponde a un sistema de edad joven–intermedia, en concordancia con lo esperado para este objeto. Además, se observa que las magnitudes y colores (indicadores de temperatura efectiva) de las estrellas miembros presentan una coherencia notable entre sí, lo que refuerza la consistencia de la selección basada en probabilidades de pertenencia.

Por otra parte, para el cúmulo Coma Berenices, aunque se observa una concentración de miembros a lo largo de la secuencia principal, es evidente que hay una sobrepoblación de estrellas. Esto sugiere que la clasificación de miembros para este cúmulo es menos precisa, probablemente debido a la mayor contaminación por estrellas de campo y a la superposición cinemática entre ambas poblaciones.

II.B Modelo no supervisado: HDBSCAN

Para la aplicación del algoritmo HDBSCAN se utilizó un espacio tridimensional definido por los movimientos propios en ascensión recta ($\mu_{\alpha*}$), declinación (μ_δ) y la paralaje (ϖ). La inclusión de la paralaje permite incorporar información sobre la distancia de las estrellas, lo que contribuye a mejorar la separación entre los miembros del cúmulo y las estrellas pertenecientes al campo estelar.

Como número mínimo de elementos para la identificación de un clúster (*min_cluster_size*) se adoptó un valor de 100. Esta elección se basa en estimaciones teóricas y observacionales reportadas en la literatura, que indican que los cúmulos abiertos suelen contener entre 10^2 y 10^3 estrellas. De esta manera, se busca evitar la detección de agrupaciones espurias formadas por un número reducido de objetos.

Por otro lado, el parámetro *min_samples* se fijó en un valor de 6, siguiendo la recomendación de la documentación oficial del algoritmo HDBSCAN, la cual sugiere utilizar un valor cercano al doble de la dimensionalidad del espacio de características. En este caso, al trabajar en un espacio tridimensional, un valor de $2 \times 3 = 6$ permite obtener estimaciones de densidad más robustas.

Para el cúmulo M41, el algoritmo HDBSCAN identificó dos clústeres principales: uno compuesto por 639 estrellas (cluster 0) y otro por 330 estrellas (cluster 1). De manera análoga, para el cúmulo Coma Berenices se identificaron dos clústeres con 3028 y 164 estrellas, respectivamente. Estas agrupaciones pueden distinguirse visualmente en el Diagrama de Vector Puntual (PVD), donde los miembros de cada clúster presentan movimientos propios similares.

Sin embargo, en el caso del cúmulo Coma Berenices se observa una superposición más marcada entre las agrupaciones identificadas y la distribución del campo estelar. Este comportamiento es consistente con la naturaleza más dispersa de este cúmulo, así como con su menor contraste cinemático respecto al fondo estelar, lo que dificulta la identificación clara de sus miembros únicamente a partir de los movimientos propios.

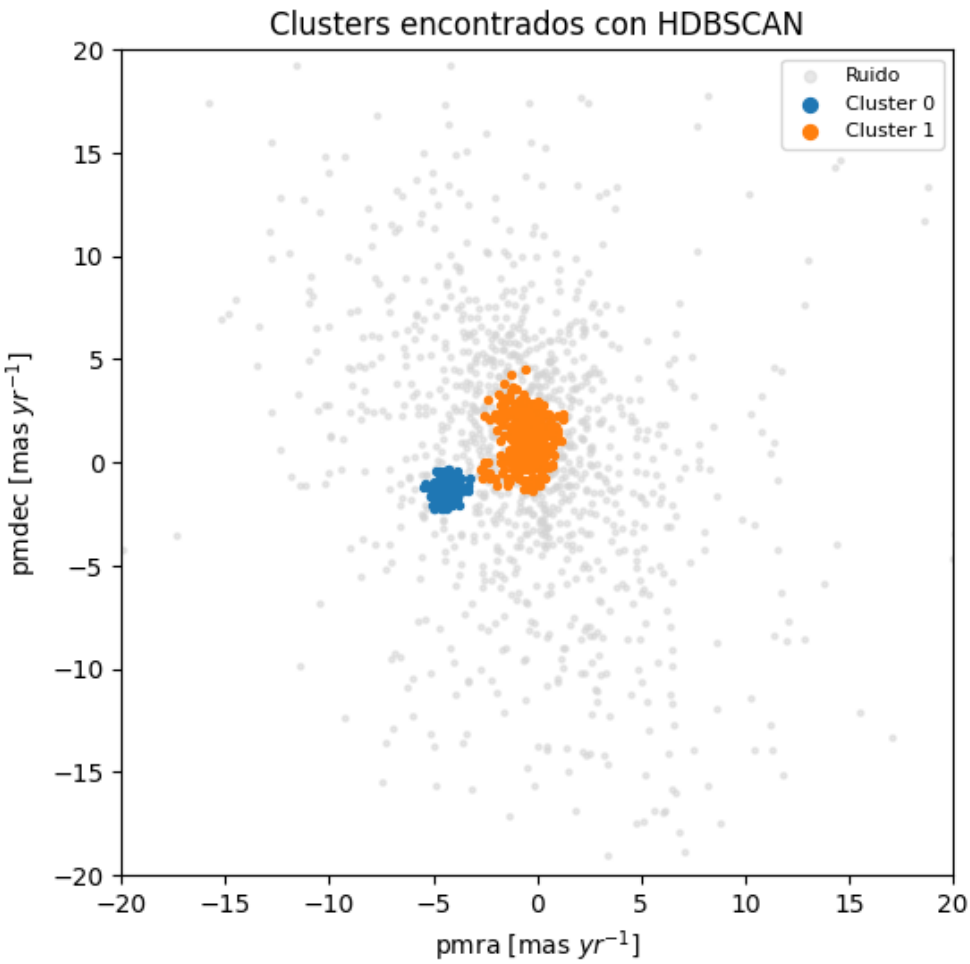

Figure 12: Diagrama de Vector Puntual (PVD) del cúmulo M41 con los clústeres identificados mediante el algoritmo HDBSCAN.

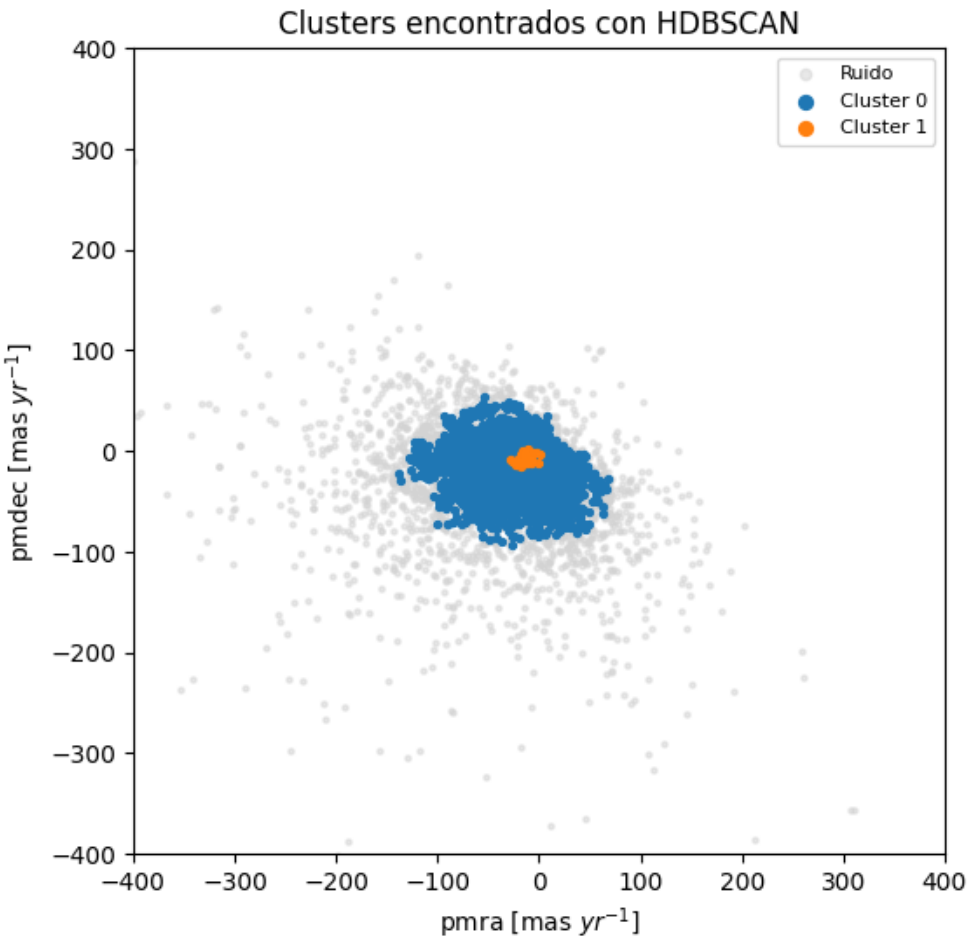

Figure 13: Diagrama de Vector Puntual (PVD) del cúmulo Coma Berenices con los clústeres identificados mediante el algoritmo HDBSCAN.

Visualización de Miembros y Campo

Con el fin de evaluar la naturaleza de los clústeres identificados mediante HDBSCAN, se construyeron diagramas color–magnitud (CMD) utilizando las magnitudes fotométricas proporcionadas por *Gaia*. Estos diagramas permiten analizar la coherencia evolutiva de las poblaciones estelares identificadas por el algoritmo de clustering.

En el caso de M41, los miembros del clúster 0 se distribuyen principalmente a lo largo de la secuencia principal en el CMD, lo que sugiere que este grupo corresponde a las estrellas miembro del cúmulo. Por otro lado, los miembros del clúster 1 se concentran mayoritariamente en la región de estrellas más débiles, con algunas pocas estrellas dispersas

cerca de la secuencia principal. Este comportamiento indica que dicho grupo probablemente está compuesto principalmente por estrellas de campo.

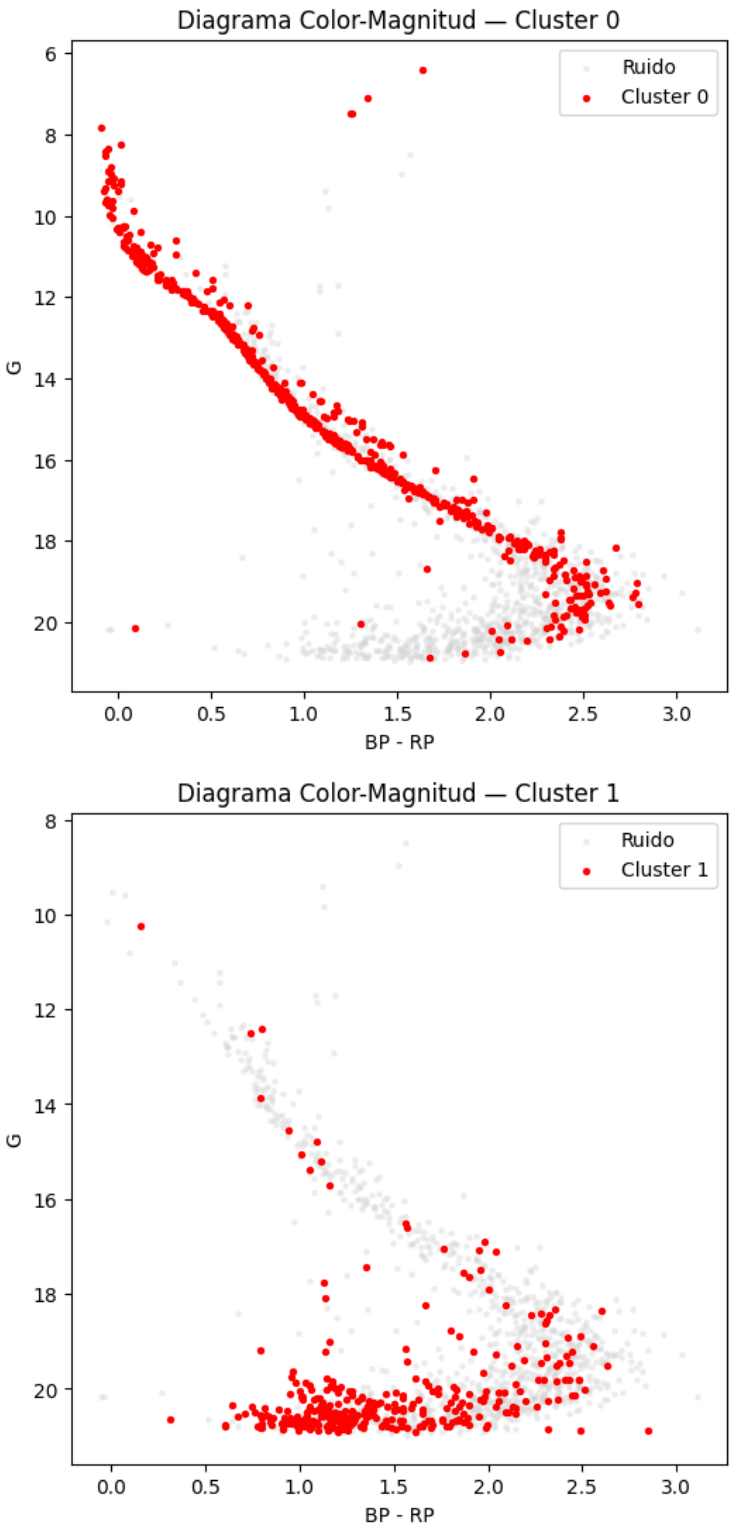

Figure 14: Diagramas color–magnitud (CMD) de los clústeres identificados por HDBSCAN para el cúmulo M41. El clúster 0 muestra una clara concentración de estrellas a lo largo de la secuencia principal, mientras que el clúster 1 presenta una distribución más dispersa, característica de estrellas de campo.

Para el cúmulo Coma Berenices se observa un comportamiento diferente. Los miembros del clúster 0 presentan una distribución más dispersa en el CMD, incluyendo estrellas ubicadas en regiones correspondientes a enanas blancas, la secuencia principal y algunas en la rama de gigantes rojas. Esta diversidad de etapas evolutivas sugiere que este grupo está dominado por estrellas del campo estelar. En contraste, el clúster 1 muestra una concentración más clara de estrellas a lo largo de la secuencia principal, lo que indica que este grupo probablemente corresponde a los verdaderos miembros del cúmulo.

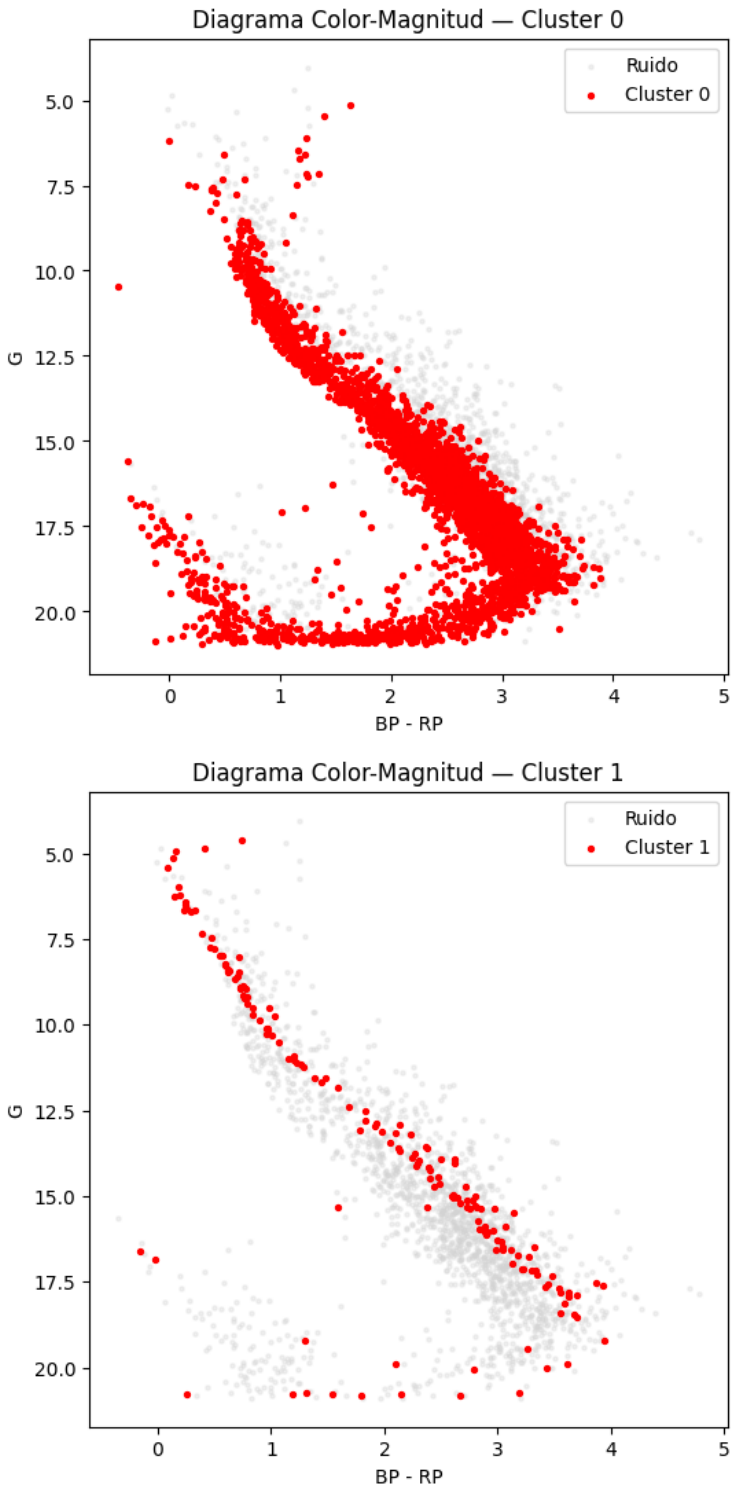

Figure 15: Diagramas color–magnitud (CMD) de los clústeres identificados por HDBSCAN para el cúmulo Coma Berenices. El clúster 0 muestra una distribución más dispersa con estrellas en diversas etapas evolutivas, característica del campo estelar, mientras que el clúster 1 presenta una concentración de estrellas a lo largo de la secuencia principal, consistente con la población del cúmulo.

Siluetas y Validación de Clústeres

Con el objetivo de evaluar la calidad de los clústeres identificados por el algoritmo HDBSCAN, se calculó el coeficiente de silueta para cada punto del conjunto de datos. Este coeficiente cuantifica qué tan similar es un objeto a los elementos de su propio clúster en comparación con los de otros clústeres, proporcionando una medida de la cohesión interna y de la separación entre agrupaciones. Valores cercanos a 1 indican una buena separación entre clústeres, mientras que valores cercanos a 0 sugieren una superposición significativa entre las agrupaciones.

En el caso del cúmulo M41, el coeficiente de silueta promedio para los miembros del clúster 0 fue de 0.540, lo que indica una buena cohesión interna y una separación razonable respecto al clúster 1. Por otro lado, el clúster 1 presentó un coeficiente de silueta promedio de 0.304, lo que sugiere una menor cohesión y una mayor superposición con el campo estelar. Además, el valor promedio de silueta para el conjunto completo de estrellas fue de 0.460. Considerando estos valores, junto con la información proporcionada por los diagramas color–magnitud, se puede concluir que el clúster 0 corresponde a los miembros del cúmulo M41, mientras que el clúster 1 está dominado principalmente por estrellas de campo.

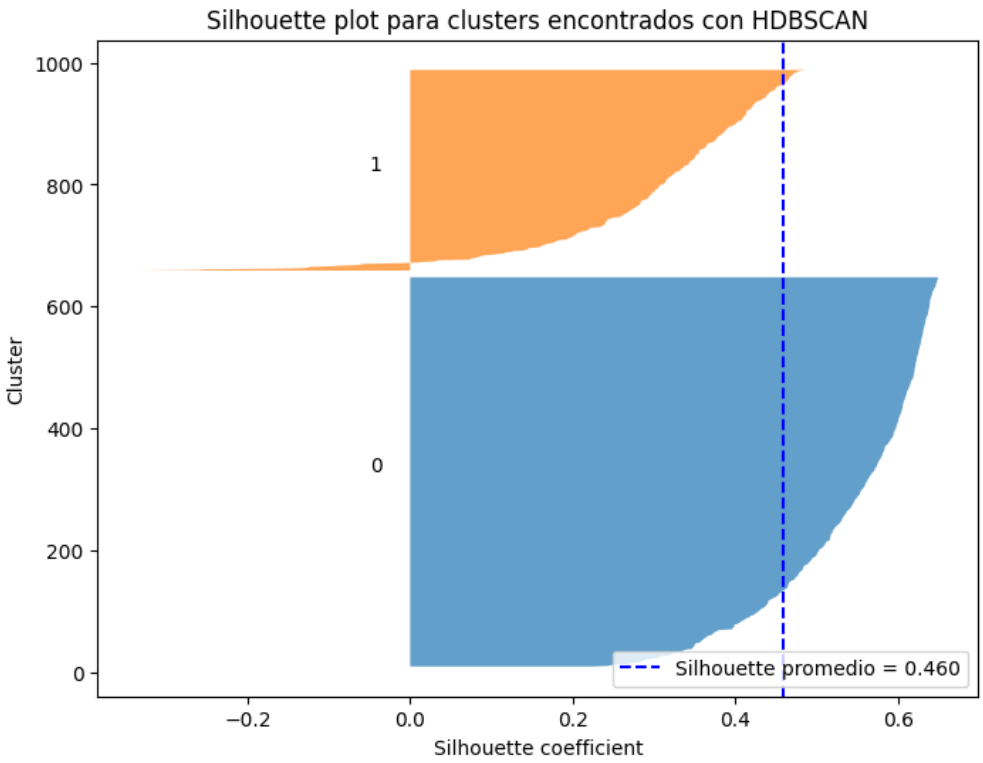

Figure 16: Diagrama de silueta para los clústeres identificados mediante HDBSCAN en el cúmulo M41.

En el caso de Coma Berenices, el coeficiente de silueta promedio para el clúster 0 fue de 0.440, lo que indica una cohesión relativamente baja y una superposición significativa con el campo estelar. En contraste, el clúster 1 presentó un coeficiente de silueta promedio de 0.861, lo que evidencia una estructura altamente cohesiva y bien separada del resto de las estrellas. El valor promedio de silueta para el conjunto completo de estrellas fue de 0.462. Estos resultados, junto con el análisis de los diagramas color–magnitud, permiten concluir que el clúster 1 corresponde a los verdaderos miembros del cúmulo Coma Berenices, mientras que el clúster 0 está compuesto principalmente por estrellas pertenecientes al campo estelar.

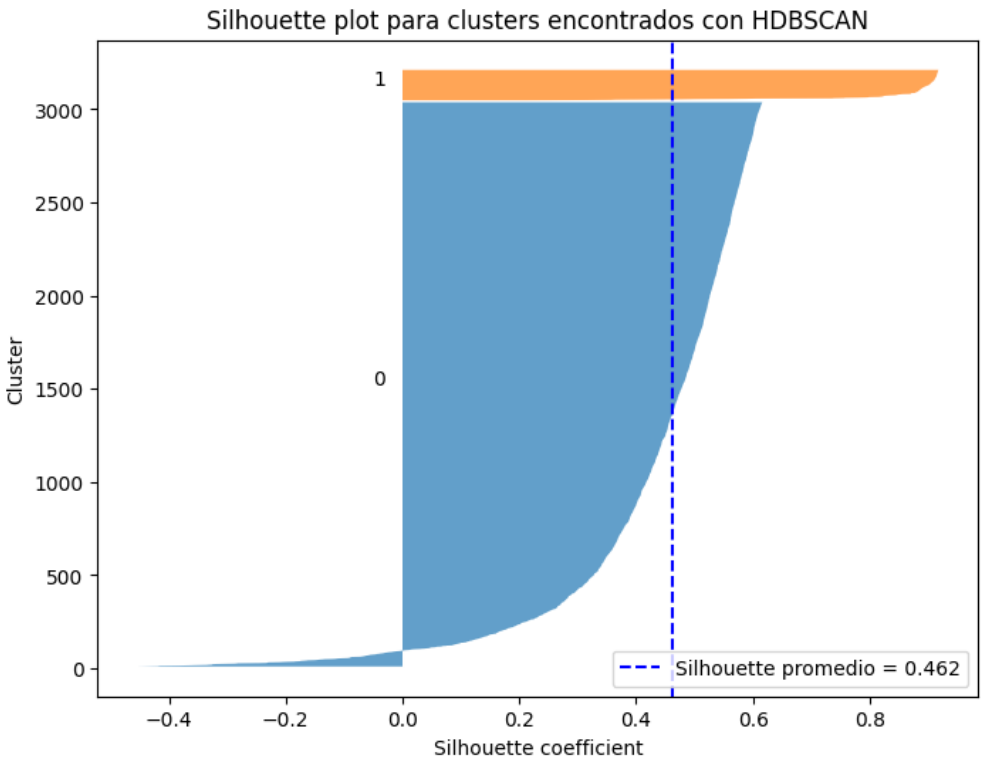

Figure 17: Diagrama de silueta para los clústeres identificados mediante HDBSCAN en el cúmulo Coma Berenices.

III. Conclusiones

En este trabajo se abordó el problema de pertenencia estelar en los cúmulos abiertos M41 y Coma Berenices utilizando dos enfoques metodológicos diferentes: un modelo de inferencia bayesiana basado en los movimientos propios y un algoritmo de aprendizaje no supervisado basado en densidad (HDBSCAN) aplicado en un espacio tridimensional de parámetros astrométricos.

El modelo bayesiano, implementado siguiendo la metodología desarrollada en el Laboratorio 2, permitió estimar probabilidades de pertenencia a partir de los movimientos propios en ascensión recta y declinación. Utilizando un umbral de pertenencia de $P > 0.5$, se identificaron 590 estrellas miembro para el cúmulo M41 y 3425 estrellas para el cúmulo Coma Berenices. Mientras que el número de miembros obtenido para M41 resulta consistente con las estimaciones reportadas en la literatura, el resultado para Coma Berenices es consider-

ablemente mayor que el esperado, lo que sugiere la presencia de una fracción significativa de falsos positivos. Este comportamiento se explica principalmente por la superposición cinemática entre las estrellas del cúmulo y el campo estelar cuando se consideran únicamente los movimientos propios.

Por otro lado, la aplicación del algoritmo HDBSCAN permitió identificar agrupaciones estelares utilizando simultáneamente los movimientos propios y la paralaje, lo que introduce información adicional sobre la distancia de las estrellas. Para el cúmulo M41 se identificaron dos clústeres principales con 639 y 330 estrellas respectivamente, mientras que para Coma Berenices se encontraron agrupaciones de 3028 y 164 estrellas. El análisis de los diagramas color–magnitud y de los coeficientes de silueta permitió identificar cuál de estas agrupaciones corresponde a los verdaderos miembros del cúmulo. En el caso de M41, el clúster con 639 estrellas muestra una clara secuencia principal en el CMD y presenta un coeficiente de silueta promedio de 0.540, lo que indica una estructura bien definida. De manera análoga, para Coma Berenices el clúster compuesto por 164 estrellas presenta una secuencia principal bien definida y un coeficiente de silueta promedio elevado (0.861), lo que confirma su identificación como la población del cúmulo.

La comparación entre ambos métodos pone de manifiesto varias diferencias importantes. El modelo bayesiano presenta la ventaja de proporcionar una interpretación probabilística directa de la pertenencia estelar y de ser computacionalmente eficiente cuando las poblaciones cinemáticas están bien separadas. Sin embargo, su desempeño puede verse limitado cuando existe una superposición significativa entre las distribuciones del cúmulo y del campo, especialmente si el análisis se realiza únicamente en el espacio de movimientos propios.

En contraste, HDBSCAN ofrece una mayor flexibilidad al no requerir asumir una forma funcional específica para las distribuciones de las poblaciones estelares, y permite identificar automáticamente estructuras de distinta densidad en espacios de mayor dimensionalidad. La inclusión de la paralaje en el análisis mejora la capacidad del algoritmo para separar miembros del cúmulo de estrellas de campo. No obstante, este método también presenta

algunas limitaciones, como la dependencia de la elección de hiperparámetros y la posibilidad de dividir una misma población física en múltiples clústeres cuando la densidad no es uniforme.

En conjunto, los resultados obtenidos muestran que la combinación de métodos estadísticos basados en modelos probabilísticos con algoritmos de clustering basados en densidad constituye una herramienta poderosa para el estudio de pertenencia estelar en cúmulos abiertos. En particular, la incorporación de información astrométrica adicional, como la paralaje, resulta fundamental para mejorar la identificación de miembros y reducir la contaminación por estrellas de campo.

IV. Repositorio de Código

Para acceder al repositorio del proyecto, visite: https://github.com/DanielFajardo1/Astronomia-con-Machine-Learning.git

Bibliography

Harris, G. L. H., Fitzgerald, M. P., & Reed, B. C. 1993, Astronomical Journal, 106, 1533

Karttunen, H. et al. 2007, Fundamental Astronomy, Springer

NOIRLab/NSF/AURA. 2020, M41, NGC 2287, https://noirlab.edu/public/images/noao-m41/, imagen astronómica del cúmulo abierto M41 en Canis Major (libre con atribución)

Ostlie, A. & Carroll, W. 1996, Modern Stellar Astrophysics, Addison-Wesley Publishing Company

Slovak, M. H. 1977, Astronomical Journal, 82, 818

Vasilevskis, S., K. A. . P. G. 1958, Astronomical Journal, 63, 387