

Clasificación de Estrellas Variables con Datos OGLE del Disco Sur Eclíptico (GSEP)

Daniel Fajardo Poveda¹

Universidad de los Andes, Bogotá, Colombia

May 24, 2026

En este trabajo se presenta un modelo de clasificación de estrellas variables basado en datos de OGLE correspondientes al disco sur eclíptico (Galactic South Ecliptic Pole, GSEP). El objetivo principal es desarrollar un clasificador de Random Forest capaz de distinguir entre diferentes tipos de variabilidad estelar, enfocándose en tres clases principales: binarias eclipsantes (EB), pulsadores radiales (RP) y variables de largo período (LPV).

El conjunto de datos original contiene múltiples clases específicas de estrellas variables, incluyendo diferentes tipos de cefeidas, RR Lyrae, binarias eclipsantes, y otros objetos. Sin embargo, se identificó que la clase OTHER, que agrupa tipos de variabilidad distintos a EB, LPV y RP, presenta contaminación significativa de elementos que exhiben morfologías típicas de estas tres clases principales, lo cual reduce considerablemente el desempeño del modelo. Por esta razón, se decidió entrenar el clasificador únicamente con las clases EB, LPV y RP.

El modelo utiliza características extraídas de las curvas de luz, incluyendo período, amplitud, simetría, coeficientes de Fourier (R21, phi21), skewness, kurtosis, planitud, ratio de profundidad y color V-I. Se implementó un Random Forest optimizado mediante Optuna, utilizando una división 60%-40% para entrenamiento y validación. Los resultados muestran métricas de desempeño superiores al 98% de accuracy, con alta precisión en la clasificación de las tres clases objetivo.

Palabras clave: Estrellas variables, clasificación automática, Random Forest, OGLE, aprendizaje automático, curvas de luz, binarias eclipsantes, pulsadores radiales, variables de largo período.

Abstract

¹Contacto: d.fajardo@uniandes.edu.co

This work presents a classification model for variable stars from OGLE survey corresponding to the southern ecliptic disk (Galactic South Ecliptic Pole, GSEP). The main objective is to develop a Random Forest classifier capable of distinguishing between different types of stellar variability, focusing on three main classes: eclipsing binaries (EB), radial pulsators (RP), and long-period variables (LPV).

The original dataset contains multiple specific classes of variable stars, including different types of Cepheids, RR Lyrae, eclipsing binaries, and other objects. However, it was identified that the OTHER class, which groups types of variability distinct from EB, LPV, and RP, presents significant contamination from elements that exhibit typical morphologies of these three main classes, which considerably reduces model performance. For this reason, it was decided to train the classifier only with the EB, LPV, and RP classes.

The model uses features extracted from light curves, including period, amplitude, symmetry, Fourier coefficients (R21, phi21), skewness, kurtosis, flatness, depth ratio, and V-I color. A Random Forest optimized through Optuna was implemented, using a 60%-40% split for training and validation. The results show performance metrics exceeding 98% accuracy, with high precision in classifying the three target classes.

I. Introducción

Las estrellas variables son objetos celestes cuyo brillo aparente cambia con el tiempo debido a diversos mecanismos físicos. Estos cambios pueden ser intrínsecos, como las pulsaciones estelares, o extrínsecos, como los eclipses en sistemas binarios. El estudio de las estrellas variables es fundamental para comprender la evolución estelar, determinar distancias cósmicas y estudiar la estructura galáctica.

El proyecto OGLE (Optical Gravitational Lensing Experiment) ha proporcionado una de las bases de datos más extensas de estrellas variables, con millones de objetos monitoreados durante décadas. Los datos del disco sur eclíptico (GSEP) contienen información fotométrica de alta calidad que permite caracterizar la variabilidad estelar con gran precisión (Soszyński et al. 2016).

Tipos de Variabilidad Estelar

Los principales tipos de variabilidad estelar considerados en este estudio son:

Binarias Eclipsantes (EB): Sistemas estelares binarios donde las estrellas se eclipsan mutuamente desde nuestro punto de vista, produciendo caídas periódicas en el brillo observado. Se caracterizan por curvas de luz con eclipses primarios y secundarios bien definidos.

Pulsadores Radiales (RP): Estrellas que experimentan expansiones y contracciones periódicas de su fotosfera, incluyendo cefeidas clásicas, RR Lyrae y otras variables pulsantes. Presentan curvas de luz con variaciones suaves y periódicas, típicamente con morfologías asimétricas.

Variables de Largo Período (LPV): Estrellas gigantes frías que exhiben variaciones de brillo en escalas de tiempo de decenas a cientos de días. Incluyen variables Mira y semi-regulares, caracterizadas por amplitudes grandes y períodos largos.

Además de estos tipos principales, existen otros tipos de variabilidad como pulsadores no radiales, elementos transitorios, y objetos eruptivos, que fueron agrupados inicialmente en la clase OTHER pero que, como se discutirá más adelante, presentaron problemas de clasificación debido a la contaminación cruzada con las clases principales ([Karttunen et al. 2007](#)).

II. Metodología y Análisis de Resultados

Preparación de Datos y Selección de Clases

El conjunto de datos original de OGLE GSEP contiene múltiples clases específicas de estrellas variables, incluyendo:

- Cefeidas clásicas (DCEP)
- Cefeidas de tipo W Virginis (CWB)
- RR Lyrae de tipo ab (RRAB)

- RR Lyrae de tipo c (RRC)
- Binarias eclipsantes de tipo Algol (EA)
- Binarias eclipsantes de tipo Beta Lyrae (EB)
- Binarias eclipsantes de tipo W UMa (EW)
- Variables Mira (M)
- Variables semi-regulares (SR)
- Otras clases menos numerosas

Para simplificar la tarea de clasificación y mejorar el desempeño del modelo, se decidió agrupar estas clases en cuatro categorías principales: EB (binarias eclipsantes), LPV (variables de largo período), RP (pulsadores radiales) y OTHER (otros tipos).

Sin embargo, durante el entrenamiento inicial del modelo con estas cuatro clases, se identificó un problema crítico: la clase OTHER no solo corresponde a tipos de variabilidad distintos a las ya mencionadas, sino que también presenta un número considerable de elementos clasificados originalmente como EB, LPV o RP que han caído dentro de esta categoría. Estos objetos probablemente exhiben zonas grises en sus morfologías o parámetros, lo que dificulta su clasificación inequívoca.




Figure 1: Diez ejemplos de curvas de luz de objetos clasificados en la clase OTHER, mostrando morfologías típicas de pulsadores radiales y potenciales binarias eclipsantes dobladas en fase. Esta contaminación cruzada demuestra que la clase OTHER no es homogénea y reduce significativamente la capacidad de generalización del modelo.

Considerando que la inclusión de la clase OTHER como categoría independiente resulta en la confusión del modelo de clasificación y una reducción considerable de las métricas de desempeño, se tomó la decisión de entrenar el clasificador final únicamente con las tres clases principales: RP, EB y LPV.

Características de Clasificación (Features)

El modelo de clasificación utiliza un conjunto de características extraídas de las curvas de luz fotométricas y de la información de color de cada estrella. A continuación se describen las features utilizadas y su relevancia para la tarea de clasificación:

Período: Representa el tiempo que tarda la estrella en completar un ciclo de variabilidad. Es una característica fundamental que permite distinguir entre diferentes tipos de variables. Por ejemplo, las RR Lyrae tienen períodos típicos entre 0.2 y 1 día, mientras que las variables Mira pueden tener períodos de cientos de días.

Amplitud: Magnitud de la variación de brillo. Las binarias eclipsantes suelen tener amplitudes relacionadas con la profundidad de los eclipses, mientras que las variables pulsantes pueden presentar amplitudes que dependen del tipo específico de pulsación. Esta característica se calcula como la diferencia entre el máximo y mínimo de la curva de

luz.

Simetría: Mide la asimetría de la curva de luz alrededor de su valor medio. Los pulsadores radiales clásicos típicamente muestran curvas asimétricas con ascensos rápidos y descensos lentos (o viceversa), mientras que las binarias eclipsantes suelen presentar mayor simetría entre los eclipses.

R21: Primer coeficiente de Fourier de amplitud, calculado como la razón entre la amplitud de la segunda armónica y la fundamental en el análisis de Fourier de la curva de luz. Este parámetro es especialmente útil para caracterizar la forma de las curvas de luz de variables pulsantes.

phi21: Diferencia de fase entre la segunda armónica y la fundamental en el análisis de Fourier. Junto con R21, permite caracterizar la morfología de la curva de luz y distinguir entre diferentes tipos de pulsadores.

Skewness: Tercer momento estadístico normalizado de la distribución de magnitudes. Cuantifica la asimetría de la distribución de brillo. Valores positivos indican colas hacia brillos mayores, mientras que valores negativos indican colas hacia brillos menores.

Kurtosis: Cuarto momento estadístico normalizado que mide el "apuntamiento" de la distribución de magnitudes. Permite distinguir entre distribuciones con picos pronunciados o aplanadas, lo cual es característico de diferentes tipos de variabilidad.

Planitud (Flatness): Razón entre la varianza de la curva de luz y la amplitud al cuadrado. Esta característica cuantifica qué tan "plana" es la curva de luz entre los eventos de variabilidad, siendo particularmente útil para identificar binarias eclipsantes que pasan la mayor parte del tiempo fuera de eclipse.

Ratio de Profundidad (ratio_prof): Para binarias eclipsantes, representa la razón entre las profundidades del eclipse primario y secundario. Esta característica es diagnóstica de las propiedades relativas de las dos componentes del sistema binario.

Color V-I: Diferencia entre las magnitudes en las bandas V (visual) e I (infrarrojo cercano). El color proporciona información sobre la temperatura efectiva de la estrella y es crucial

para distinguir entre diferentes poblaciones estelares. Por ejemplo, las variables Mira son típicamente muy rojas debido a su baja temperatura superficial.

Estas características fueron seleccionadas porque capturan tanto propiedades temporales (período, forma de la curva de luz) como propiedades físicas (temperatura a través del color) de las estrellas variables, proporcionando información complementaria que mejora la capacidad discriminadora del modelo.




Figure 2: Diez ejemplos de curvas de luz de pulsadores radiales (RP). Se observan las características típicas de este tipo de variables: variaciones periódicas suaves con morfologías asimétricas, ascensos rápidos seguidos de descensos lentos, y amplitudes significativas. Las cefeidas clásicas y RR Lyrae son los representantes más comunes de esta clase.




Figure 3: Diez ejemplos de curvas de luz de binarias eclipsantes (EB). Se aprecian los eclipses primarios y secundarios característicos, con profundidades que dependen de las propiedades relativas de las dos estrellas del sistema. Algunas muestran eclipses simétricos (sistemas tipo Algol o Beta Lyrae), mientras que otras presentan variaciones de contacto (tipo W UMa).




Figure 4: Diez ejemplos de curvas de luz de variables de largo período (LPV). Estas estrellas gigantes frías exhiben variaciones de gran amplitud con períodos de decenas a cientos de días. Las morfologías son más irregulares que los pulsadores radiales de período corto, reflejando la complejidad de los procesos físicos en estas estrellas evolucionadas.

División de Datos y Optimización de Hiperparámetros

Para el desarrollo del modelo de Random Forest, se utilizó una división 60% entrenamiento - 40% validación. Esta proporción permite contar con suficientes datos para entrenar el modelo mientras se reserva una fracción sustancial para evaluar su desempeño de manera robusta.

La distribución de elementos en cada conjunto se muestra en la Tabla 1:

Table 1: Distribución de elementos en los conjuntos de entrenamiento y validación

Clase	Entrenamiento (60%)	Validación (40%)	Total
EB	919	612	1531
LPV	1679	1119	2798
RP	591	394	985
Total	3189	2125	5314

Los hiperparámetros del modelo de Random Forest fueron optimizados utilizando la biblioteca Optuna, una herramienta de optimización automática que implementa algoritmos de búsqueda eficientes como Tree-structured Parzen Estimator (TPE). El proceso de optimización exploró el espacio de hiperparámetros evaluando múltiples configuraciones y

seleccionando aquella que maximiza el accuracy en validación cruzada.

Los hiperparámetros optimizados incluyen:

- **n_estimators**: Número de árboles en el bosque (256)
- **max_depth**: Profundidad máxima de cada árbol (24)
- **min_samples_split**: Número mínimo de muestras para dividir un nodo (10)
- **min_samples_leaf**: Número mínimo de muestras en una hoja (1)
- **max_features**: Número de features a considerar en cada división ('log2')

Métricas de Desempeño del Modelo

El modelo de Random Forest optimizado alcanzó un desempeño excepcional en el conjunto de validación (40% de los datos). La Tabla 2 muestra las métricas globales:

Table 2: Métricas globales del modelo en el conjunto de validación

Métrica	Valor
Accuracy	0.98
Precision (macro avg)	0.98
Recall (macro avg)	0.97
F1-score (macro avg)	0.97

El desglose por clase se presenta en la Tabla 3:

Table 3: Métricas de desempeño por clase

Clase	Precision	Recall	F1-score
EB	0.97	0.95	0.96
LPV	0.98	0.99	0.99
RP	0.98	0.96	0.97

Estas métricas indican que el modelo tiene un desempeño excelente en las tres clases:

- Las binarias eclipsantes (EBlyr) alcanzan una precisión de 0.97 y un recall de 0.95. Esto indica que el modelo es muy certero al identificarlas, manteniendo una baja

proporción de falsos positivos, y logra recuperar exitosamente a la gran mayoría de estas estrellas presentes en la muestra, consolidando un F1-score de 0.96.

- Las variables de largo período (LPV) muestran el mejor desempeño global del modelo, con una precisión de 0.98 y un recall casi perfecto de 0.99 (F1-score de 0.99). Esto demuestra que el clasificador es excepcionalmente robusto para detectar esta clase sin confundirla con las demás.
- Los pulsadores radiales (RP) presentan una precisión muy alta de 0.98 junto con un recall de 0.96 (F1-score de 0.97). Este comportamiento sugiere que cuando el modelo predice una estrella como RP, la clasificación es sumamente confiable; sin embargo, al tener un recall ligeramente menor, existe una pequeña fracción de estos pulsadores que el modelo pasa por alto o asigna incorrectamente a otra clase.

Importancia Relativa de las Características

El análisis de importancia de features del Random Forest permite identificar cuáles características contribuyen más a las decisiones del modelo. La Tabla 4 muestra la relevancia relativa de cada feature:

Table 4: Importancia relativa de las características utilizadas

Feature	Importancia
V-I	0.377
amplitud	0.203
skewness	0.127
kurtosis	0.110
periodo	0.067
phi21	0.058
R21	0.026
simetria	0.019
planitud	0.007
ratio_prof	0.005

El índice de color V-I es, por un margen considerable, la característica más importante (37.7%). Esto tiene un profundo sentido físico, ya que sirve como un indicador directo de la temperatura efectiva de la estrella, permitiendo al modelo separar eficientemente las diferentes poblaciones de variables que habitan regiones distintas del diagrama de

Hertzsprung-Russell. La amplitud se consolida como la segunda característica más relevante (20.3%), seguida por los momentos estadísticos que describen la morfología de la curva de luz, como la asimetría o *skewness* (12.7%) y la *kurtosis* (11.0%).

Resulta interesante observar que el período tiene una contribución secundaria (6.7%) frente a la información fotométrica y de forma. Finalmente, es notable que el ratio de profundidad (`ratio_prof`), un parámetro diseñado para capturar la geometría y los mínimos de luz característicos de las binarias eclipsantes (EBlyr), tenga la importancia más baja del conjunto (0.5%). Esto ocurre probablemente porque es un rasgo altamente específico que solo resulta informativo para identificar una sola de las clases presentes en la muestra, permaneciendo "latente" para el resto de los tipos de variabilidad.

Matriz de Confusión

La matriz de confusión proporciona información detallada sobre los errores de clasificación del modelo. La Figura 5 muestra la matriz de confusión obtenida en el conjunto de validación:




Figure 5: Matriz de confusión del clasificador Random Forest. Los valores en la diagonal representan clasificaciones correctas, mientras que los elementos fuera de la diagonal indican errores. Se observa que la gran mayoría de las predicciones caen en la diagonal, con confusiones mínimas entre clases.

Las confusiones observadas son consistentes con las similitudes físicas y morfológicas entre algunos objetos. Por ejemplo, ciertas binarias de tipo Beta Lyrae (EBlyr) en fuerte interacción geométrica pueden presentar variaciones continuas en sus curvas de luz que el modelo asimila a pulsaciones radiales. De igual forma, algunas variables semi-regulares podrían confundirse con otras clases dependiendo del muestreo temporal y la fase de observación capturada. Sin embargo, estas confusiones son mínimas y no afectan significativamente el desempeño global del modelo, que mantiene una alta precisión y recall en las tres clases principales.

Análisis de Correlación de Características

Para evaluar la redundancia de las características utilizadas, se calculó la matriz de correlación de Spearman entre todas las features. La Figura 6 muestra los resultados:




Figure 6: Matriz de correlación de Spearman entre las características utilizadas. Los valores cercanos a ± 1 indican alta correlación (positiva o negativa), mientras que valores cercanos a 0 indican independencia. Se observa que todas las features presentan correlaciones bajas, indicando que aportan información complementaria al modelo.

El análisis de correlación revela que las características utilizadas son poco redundantes, ya que no están altamente correlacionadas entre sí. La mayoría de los coeficientes de correlación de Spearman tienen valores absolutos menores a 0.5, lo que indica que cada feature aporta información relativamente independiente al modelo. Esto es crucial para el desempeño del Random Forest, ya que permite que cada árbol del bosque aproveche diferentes aspectos de la información disponible, mejorando la capacidad de generalización y reduciendo el riesgo de sobreajuste a características específicas.

III. Conclusiones

En este trabajo se desarrolló exitosamente un modelo de clasificación automática de estrellas variables basado en Random Forest, utilizando datos del relevamiento OGLE correspondientes al disco sur eclíptico (GSEP). A través de este desarrollo, se demostró que

la simplificación del problema de clasificación a tres grupos principales, binarias eclipsantes de tipo Beta Lyrae (EBlyr), pulsadores radiales (RP) y variables de largo período (LPV), optimiza significativamente el desempeño global del clasificador, evitando la introducción de una categoría genérica y heterogénea que suele contaminar los algoritmos de aprendizaje automático.

El modelo alcanzó métricas de desempeño sobresalientes y altamente equilibradas, registrando puntajes F1-score que van desde 0.96 hasta un robusto 0.99. En particular, las variables de largo período (LPV) exhibieron el comportamiento más robusto con una precisión de 0.98 y un *recall* de 0.99 (F1-score de 0.99), seguidas de cerca por los pulsadores radiales (RP) con un F1-score de 0.97 y las binarias eclipsantes (EB) con un F1-score de 0.96. Estas métricas evidencian que las confusiones observadas entre las clases son mínimas, presentándose únicamente en los límites morfológicos esperados y físicamente razonables dentro de la variabilidad estelar.

Por otro lado, el análisis cuantitativo de la relevancia de los parámetros reveló que el índice de color V-I es, con un 37.7%, la característica más determinante para las decisiones del modelo, lo cual posee un sólido respaldo astrofísico al vincularse directamente con la temperatura efectiva de las poblaciones estelares. La amplitud se consolidó como el segundo descriptor más relevante (20.3%), seguida por los momentos estadísticos de orden superior de la curva de luz, la asimetría o *skewness* (12.7%) y la *kurtosis* (11.0%), relegando al período a una contribución secundaria del 6.7%. Asimismo, el examen de dependencias confirmó la total ausencia de características altamente correlacionadas en el conjunto final, validando la selección de atributos y asegurando que el Random Forest aprovechara información ortogonal y complementaria.

Trabajo Futuro

Los resultados obtenidos abren varias líneas de investigación futuras:

- Extensión del modelo para incluir subclases específicas dentro de cada categoría principal (e.g., distinguir entre cefeidas clásicas y RR Lyrae dentro de los pulsadores radiales).

- Exploración de arquitecturas de aprendizaje profundo (redes neuronales convolucionales, recurrentes o transformers) que puedan aprender características directamente de las curvas de luz sin necesidad de feature engineering.
- Aplicación del modelo a otros campos del relevamiento OGLE para evaluar su capacidad de generalización a diferentes poblaciones estelares.

En conclusión, este trabajo demuestra que los métodos de aprendizaje automático, específicamente Random Forest optimizado, son herramientas poderosas para la clasificación automática de estrellas variables en grandes relevamientos fotométricos. Los modelos desarrollados pueden contribuir significativamente al procesamiento eficiente de los enormes volúmenes de datos que generan y generarán los relevamientos actuales y futuros, liberando tiempo de los investigadores para el análisis científico detallado de los objetos más interesantes.

References

Karttunen, H. et al. 2007, *Fundamental Astronomy*, Springer

Soszyński, I. et al. 2016, *Acta Astronomica*, 66, 405

V. Repositorio de Código

El código completo de este proyecto, incluyendo notebooks de análisis exploratorio, scripts de entrenamiento y evaluación del modelo, está disponible en el repositorio de GitHub del autor. Para acceder al repositorio del proyecto, visite: <https://github.com/DanielFajardo1/Astronomia-con-Machine-Learning.git>